



华中农业大学

HUAZHONG AGRICULTURAL UNIVERSITY

硕士学位论文

MASTER'S DEGREE DISSERTATION

基于深度学习与 RGB 图像的土壤类型与诊断层识别研究

RESEARCH ON SOIL TYPE AND DIAGNOSTIC HORIZON
IDENTIFICATION BASED ON
DEEP LEARNING AND RGB-IMAGERY

研究生: 杨瑞清

CANDIDATE: YANG RUIQING

学 号: 2020303120154
STUDENT NO.:

学位类别: 农业硕士

DEGREE TYPE: MASTER OF AGRICULTURE

导 师: 陈家赢 副教授

SUPERVISOR: ASSO. PROFESSOR CHEN JIAYING

中国 武汉
WUHAN, CHINA

二〇二二年六月

JUNE, 2022

华中农业大学硕士学位论文

基于深度学习与 RGB 图像的土壤类型 与诊断层识别研究

Research on soil type and diagnostic horizon identification
based on deep learning and RGB-imagery

研 究 生：杨瑞清

学 号：2020303120154

指 导 教 师：陈家赢 副教授

指 导 小 组：杨勇 教授

刘诗诗 副教授

傅佩红 副教授

汪善勤 副教授

张海涛 副教授

郭龙 讲师

专业：农业工程与信息技术

研究方向：土壤地理

获得学位名称：农学硕士

获得学位时间：2022 年 6 月

华中农业大学资源与环境学院

二〇二二年六月

目 录

1 绪论.....	1
1.1 研究背景.....	1
1.2 国内外研究进展.....	2
1.2.1 各类传感器在土壤类型与层次识别上的研究进展	2
1.2.2 图像分类算法研究进展.....	3
1.2.3 语义分割算法研究进展.....	5
1.3 研究内容和技术路线.....	7
1.3.1 研究目的与内容.....	7
1.3.2 技术路线.....	8
2 研究数据与方法	10
2.1 研究区土壤采样点总览概况	10
2.1.1 土纲及其亚纲采样点分布概况.....	10
2.1.2 采样点中土壤诊断层分布及信息统计	12
2.2 图像数据集.....	16
2.2.1 土纲及亚纲原始数据集.....	17
2.2.2 层次原始数据集.....	19
2.3 数据预处理.....	22
2.3.1 图像裁剪与压缩.....	22
2.3.2 数据增强.....	23
2.3.3 图像标注.....	24
2.4 深度学习算法.....	25
2.4.1 ResNet.....	25
2.4.2 UNet++.....	27
2.5 评价指标.....	28
2.5.1 准确率.....	29
2.5.2 召回率.....	29
2.5.3 均交并比.....	29
2.5.4 像素精度.....	30
3 基于 ResNet 的土壤类型识别.....	31
3.1 土壤类型识别模型.....	31
3.1.1 实验设备与环境配置.....	31
3.1.2 参数设置.....	31
3.1.3 训练过程.....	32
3.2 结果分析.....	33

3.2.1 土纲数据集.....	33
3.2.2 亚纲数据集.....	34
3.2.3 误判分析.....	35
3.3 本章小结.....	36
4 基于 UNet++的土壤诊断层识别	38
4.1 土壤诊断层识别模型建立	38
4.1.1 实验设备与环境配置.....	38
4.1.2 参数设置.....	38
4.1.3 训练过程.....	39
4.2 结果分析.....	42
4.2.1 模型验证.....	42
4.2.2 误判分析.....	45
4.3 本章小结.....	46
5 总结与展望.....	48
5.1 主要结论.....	48
5.2 不足与展望.....	49
参考文献.....	51

摘要

定量化的土壤系统分类能更加准确地表达土壤的性质差异，是土壤信息量化表达和应用推广的基础。通过土壤系统分类得到的土壤类型结果反映了数量化的发生环境和土体特征，可以实现土壤信息在不同指标体系间的交流转换，因而受到更多学者的青睐。在土壤系统分类中，诊断层的鉴定一定程度上决定了土壤类型的最终判定，同时对土壤的数值化研究与演化机制研究有着重要作用。然而，在实际的土壤类型、诊断层的鉴定过程中，测定土壤理化数据是基础工作，不仅繁琐且费时费力。近年大量的传感器诞生并用于土壤分类和土壤制图以快速高效地完成这一工作，如高光谱成像仪、便携式 X 荧光仪（PXRF）等。然而目前研究中采用的传感器数据获取不仅操作较为复杂，且设备价格高昂，难以普及。实际中野外工作者们正亟需一种快速高效又便捷廉价的方式确定土壤类型与层次信息。

针对这一问题，本文以湖北省和江西省土系调查中拍摄的主要土体剖面照片为基础，通过数据预处理，形成了土纲数据集、亚纲数据集、层次数据集。在分别采用深度残差网络 ResNet 和语义分割网络 UNet++ 建立土壤类型识别模型和土壤诊断层识别模型，并进行精度评价，分析不同类型与土壤诊断层的特征进行误判分析。主要结论如下：

（1）土壤类型识别研究中，对同一原始数据集，在不同分类层级上建立的土纲、亚纲层级的土壤类型识别模型两者在训练集上总体准确率都接近 100%，在测试集上总体准确率分别为 90.88% 与 93.71%。土壤诊断层识别研究中，最终模型的均交并比与像素精度分别为 71.24%、82.66%。总体准确率均表现优秀，因此利用土体剖面 RGB 图像进行土壤类型与土壤诊断层识别具有可行性。同时土壤类型识别研究的结果也表明随着类型层级的深入，总体准确率也会随之提升。

（2）对土壤类型之间以及土壤诊断层之间出现的误判情况进行分析，发现在识别过程中的精度表现、结果图像表现由于土壤系统分类中其自身的定义以及诊断条件在 RGB 图像上的视觉特征适用范围是否宽泛、样本数量多少、研究区土壤特性而相差较大。土壤类型识别研究中，土纲层级识别能力依次为新成土>富铁土>人为土>淋溶土>锥形土，亚纲层级识别能力依次为正常新成土=潮湿锥形土>湿润富铁土>湿

润淋溶土>水耕人为土>湿润雏形土。土壤诊断层识别研究中，识别能力依次为水耕氧化还原层>水耕表层>雏形层>暗瘠、暗沃表层 $\approx$ 淡薄表层>黏化层（低活性富铁层） $\approx$ 黏化层>低活性富铁层，诊断表层的精度表现总体上优于诊断表下层。

关键词：土壤系统分类；土壤诊断层；深度学习；图像分类；语义分割

Abstract

The quantitative method, Chinese Soil Taxonomy (CST, 3rd version), can accurately express the difference of soil properties and is the basis for quantitative expression of soil information and application promotion. The soil type results obtained through the CST reflect the quantitative pedogenetic environment and soil characteristics, which can realize the exchange and conversion of soil information between different index systems, and thus are favored by more scholars. In the CST, the identification of diagnostic horizon determines the final determination of soil type to a certain extent and also plays an important role in the numerical study of soil and the study of evolutionary mechanisms. However, in the practical process of soil type and diagnostic horizon identification, the measurement of soil physical-chemical data is the basic work, which is not only tedious but also time-consuming and laborious. In recent years, a large number of sensors have been created and used for soil classification and soil mapping to perform this work quickly and efficiently, such as imaging spectrometers and portable X-ray fluorescence instruments (PXRF). Yet the sensors used in current research are not only more complicated to acquire data, but also more expensive to instrument. Therefore, field workers are in urgent need of a fast, efficient, convenient, and cheaply-priced way to identify soil type and diagnostic horizon.

To address this issue, the profile images of major soil types taken by DSLR cameras in Hubei and Jiangxi provinces were selected for this study. Through data pre-processing, three datasets were formed, including soil datasets at the order level and the suborder level for soil type identification and a dataset for soil diagnostic horizon identification. After applying the deep residual network ResNet and the semantic segmentation network UNet++ to get the soil type identification models and the soil diagnostic horizon identification model respectively, the accuracy evaluation was carried out, and the misclassification analysis was performed for the characteristics of different soil types and soil diagnostic horizons. The main results are as follows:

(1) In the soil type identification study, for the same original dataset, the overall accuracy of the soil type identification models established at different classification levels for both order and suborder levels were close to 100% on the training set and 90.88% and 93.71% on the test set, respectively. In the soil diagnostic horizon identification study, the mean intersection over union and pixel accuracy of the final model were 71.24% and 82.66%, respectively. The overall accuracies were excellent, thus proving the feasibility of

using soil profile images for soil type and soil diagnostic horizon identification. The results of the soil type identification study also indicate that the overall accuracy will increase with the deeper of the classification layer.

(2) Analysis of the misclassification between soil types and soil diagnostic horizons reveals that the accuracy performance and the resultant image performance in the identification process varied widely depending on the definition in the CST and the applicability of the visual characteristics of the diagnostic conditions on the RGB images, the number of samples, and the soil characteristics of the study area. In the study of soil type identification, the ability to identify the soil type at the order level is from the highest to the lowest in the order of Primosols, Ferrosols, Anthrosols, Argosols, and Cambosols; the ability to identify the soil type at the suborder level is from the highest to the lowest in the order of Orthic Primosols, Aquic Cambosols, Udic Ferrosols, Udic Argosols, Stagnic Anthrosols, and Udic Cambosols. In the soil diagnostic horizon identification study, the identification ability from the highest to the lowest in the order of Hydragric horizon > Anthrostagnic epipedon > Cambic horizon > Umbric or Mollic epipedon $\approx$ Ochric epipedon > Argic horizon (LAC-ferric horizon) $\approx$ Argic horizon > LAC-ferric horizon, and the accuracy performance of diagnostic surface horizons was generally better than that of diagnostic subsurface horizons.

Key words: Chinese Soil Taxonomy; Diagnostic horizon; Image classification; Semantic segmentation

1 绪论

1.1 研究背景

土壤布在田，能者以为富，土壤是人类文明演进与经济发 展的基石，研究土壤、认识土壤、利用土壤可助力规划农业生产，在有限的耕地范围内统筹作物种植，显著降低农民种植风险，从而保障国家粮食安全。其中，土壤研究的一个重要方向是对土壤进行分类，它不仅是其他学科结合土壤学成果相辅相成的重要基石（张甘霖等 2013），也是促进国内外土壤学科学术交流的重要桥梁（龚子同和张甘霖 2006）。随着精准农业、耕地质量评价、农村土地规划等科学应对粮食保障的预案被农业部所采用，其对数字土壤制图的精度与土壤分类准确度的要求也愈发提高（孟祥添等 2018）。然而传统土壤分类方法主要基于土壤发生学理论知识体系，是一种通过专家判定的定性分类方法，其分类结果容易因人为主观经验不同而产生一定的差异，缺乏定量化的指标体系支撑。

针对传统土壤发生分类方法的不足，近年逐渐发展起来的定量化的土壤系统分类则更能准确地表达土壤的性质差异，是土壤信息定量化表达和应用推广的基础。土壤系统分类采用数量化的发生环境和土体特征，用于反映不同强度的成土过程，进而对土壤进行区分。因为定量化指标这一优势，土壤系统分类正被愈来愈多的学者推崇并进行研究。在近年来发表的研究论文中，也多采用这一分类体系（Hughes et al 2018, 王腊红等 2020, 杨家伟等 2021）。

在土壤系统分类的具体识别过程中，诊断层作为研究土壤系统分类的基本要素，是一种性质上有定量规定的特定土层，可以决定土壤类型的最终判定（中国科学院南京土壤研究所土壤系统分类课题组和中国土壤系统分类课题研究协作组 2001）。此外，土壤层次的精确划分与判别对于研究评估土壤碳储量、容重、水分运动和土壤微生物分布也很重要。（Zhang et al 2014, Zhang and Hartemink 2017, Al-Shammary et al 2018, Jiang et al 2021）。同时，精准地划分土壤层次也是数字土壤制图的重要一环（Chen et al 2022）。

然而，在实际的土壤类型、诊断层的鉴定过程中，需要消耗大量的人力物力采集样品、测定土壤理化数据，继而判断土壤诊断层与诊断特性，再综合考虑环境协

变量后，才能得到最终结果。因此，野外工作者们正亟需一种快速高效又便捷廉价的方式确定土壤类型与层次信息。随着众多传感器技术的进步，研究者们开始将其与各种现代信息技术工具结合以用于土壤分类和土壤制图，极大地推动了计量土壤学与数字土壤制图的发展（Hartemink and Minasny 2014）。

基于土壤的各种性质在土壤剖面上表现有不同的形态学上的特点（Hartemink et al 2020, Jiang et al 2021），结合快速、高效、便捷、廉价地划分土壤层次与识别土壤类型的现实需求，本文将采用以单反相机拍摄的土壤剖面照片，运用深度学习中的神经网络框架学习不同类型、不同诊断层在土壤剖面上表现的形态学差异，训练得到精度、效率表现优良的模型，并利用这些模型进行土壤类型与诊断层的识别。这将为野外土壤类型、层次判别，尤其是高级分类单元与诊断层的辨别中提供一种辅助信息，用以弥补信息缺失带来的误判，一定程度上避免经验主义，为土壤信息推广提供基础。

1.2 国内外研究进展

1.2.1 各类传感器在土壤类型与层次识别上的研究进展

运用单一传感器或是多种传感器相互结合以进行土壤数值研究是土壤学研究中的一大热门方向，这证明了传感器所感知的信息数据可以用于表征土壤中的部分数值信息（Barra et al 2021），与土壤系统分类或者诊断层鉴别的定量化指标要求特征相符合。因此，近年来有部分研究者选择直接通过传感器数据以训练建立土壤类型或者土壤层次的识别预测模型（Searle et al 2021）。

高光谱成像仪，作为土壤学中研究最为热门的传感器之一，在土壤类型识别方面却应用较少。有研究者尝试运用高光谱数据进行土壤类型的预测，但其模型仅在土纲与亚纲上表现良好，总体验证精度分别为0.63与0.62，在土类与亚类则表现较差，精度仅有0.40与0.28（Xie and Li 2018）。而对于运用高光谱数据进行土壤层次识别而言，目前相关研究较缺乏。因此土壤的光谱信息可以作为土壤系统分类的信息来源，但值得一提的是高光谱的成像条件要求苛刻且仪器费用高昂，导致了其在实际中应用的便捷性较差。

便携式X射线荧光分析仪（PXRF），一种基于X射线的多元素测定分析仪器，具

有成本低、效率高、便携性好等优点。因其能在土壤中有效测定出近30种元素含量，在土壤重金属检测优势明显，但也有少部分学者尝试使用这类数据进行土壤类型或层次识别。在土壤类型识别方面，Benedet等人结合使用PXRF和Vis-NIR两种数据，对土壤样品进行亚类层级上的识别，取得了较高精度（Benedet et al 2020）。在土壤层次识别方面，也有学者提出可通过土壤剖面的连续PXRF数据证明元素含量可以作为辅助数据有效地指导土壤层次划分（Weindorf et al 2012）。在此基础上，周泽璠对原位测定的土壤剖面PXRF数据进行聚类分析，较准确地划定了土壤发生层，同时通过机器学习算法进行了诊断层识别（周泽璠 2021）。尽管这些研究都证明了PXRF数据可以用于土壤类型或层次识别，但由于该数据主要与土壤中元素含量相关，难以表征更多的土壤形态信息，因而更适合于作为辅助数据使用。

单反相机与智能手机，作为现代最为广泛使用的摄像设备之一，其光学性能与可用性均得到大幅度提升，且其低成本、小型化的优点也吸引了国内外大量学者利用这些设备制作数据集，并对其进行研究。其中 Han 等人使用智能手机对采集回来的标准土样进行拍摄，并基于可见光谱和机器视觉测试，实现了快速且较为准确的土壤分类（Han et al 2016）。但该方案需要利用标准土样图像进行土壤类型识别，由于标准土样的制作繁琐，同时会损失土壤在深度上所涵盖的信息，导致该分类方法的泛用性与即时性较弱。Zhang 等人则运用数码相机获得的土壤剖面图像，结合图像中的颜色、纹理等特征，运用 k-means 聚类的方法对土壤剖面进行分割，实现了较好的土壤层次边界绘制自动化（Zhang and Hartemink 2019）。但这一方法局限于层次边界的绘制，缺乏层次类型的识别，提供的信息较为有限。Jiang 等人则通过单反相机获取土壤剖面照片，运用神经网络训练得到了精度较高的发生层识别模型（Jiang et al 2021），其研究中是将层次归入 A、B、C 共 3 个类型中，进而进行识别。因此，通过普通相机或智能手机内置摄像头获得的图像信息就可以完成土壤分类以及层次识别的任务，并且能达到不错的实验精度，除此之外，这些设备还具有快速、高效、便捷、廉价等优点，对土壤类型与层次识别的实验设计适用性较高。

1.2.2 图像分类算法研究进展

图像分类（Image classification），即给定一幅输入图像（在本研究中则是给定一

幅土壤剖面的 RGB 图像), 通过某种算法训练出一个可以捕捉到每一类图像特征的分类器, 以对图像所属的类别做出判别的过程。因此, 这一算法技术将满足本研究中土壤类型识别的需求。

传统的图像分类算法较为依赖人工选取的特征, 包括颜色、纹理等较为初级的底层视觉特征, 而后也出现有方向梯度直方图 (Déniz et al 2011)、尺度不变特征变化 (Grabner et al 2006)、局部二值模式 (He et al 2005) 等具有一定普适性且统计意义上的局部不变特征的分类算法, 但当其面对具体的图像以及特定的划分方式时容易出现针对性不够的问题。然后是更为常见的较为传统的分类器, 这一类包括 KNN(K-nearest neighbor) (Amato and Falchi 2011)、SVM (Support vector machine) (Joachims 2006) 等分类算法。这些分类算法在对一些简单的图像进行分类时, 可能精度表现良好同时操作实现简单, 但无法解决实际应用中的差异较弱、干扰较多的图像分类问题, 此时精度表现将大幅下降, 难以现实应用 (杨真真等 2018)。

在计算机视觉领域, 随着人工智能技术与计算机硬件条件的蓬勃发展, 深度学习逐渐被应用于各行各业的图像分类研究, 并成为热点方向。这是一种通过学习文本、音频、图像等给定数据自动提取特征并直接学习的方法。在交叉学科中已涌现了许多通过深度学习训练得到的优秀模型, 如: 医学图片诊断模型 (Coudray et al 2018, Mohamed et al 2018)、植物识别模型 (鲁梦瑶等 2018)、紫色土心土图像分类模型 (曾莉 2019) 等。

在深度学习庞大的算法库中, 卷积神经网络 (Convolutional neural networks, CNN) 应用非常广泛。2012 年, Krizhevsky 等人在 ImageNet 竞赛中首次应用设计的 AlexNet 架构, 针对数据集训练得到的准确率高达 84.6%, 对比其它参赛团队取得巨大优势并夺冠。此后, 自 SVM 后再无波澜的人工智能学科, 正式掀起了又一波以 CNN 与各个学科领域结合的应用热潮。因此也引来了大量的学者将目光投向 CNN 领域研究 (Krizhevsky et al 2012), 在经过广泛激烈的论证之后, CNN 架构不断得到完善, 目前广泛应用的成熟 CNN 模型架构主要由输入层、卷积层、池化层、全连接层、输出层等组成。得益于生物神经网络的启发, CNN 具备的非全连接和权值共享的网络结构, 使得其在图像分类领域有着不容忽视的影响力 (周俊宇和赵艳明 2017)。在过去的几年里, 刘兰军等人选用卷积神经网络对土壤光谱进行建模分析, 得到的结

果证明优化后 CNN 土壤光谱分析模型相比传统的 PLS 等模型准确率更高（刘兰军等 2020）；钟亮等在对比分析 CNN、多层感知器与几种常见的机器学习方法在红壤高光谱数据上应用的有机质含量估算效果时发现 CNN 不仅能够简化光谱预处理过程，同时也能快速、精确地估算有机质的含量，因而具有广阔的发展前景（钟亮等 2021）。

在图像分类领域中 CNN 的发展往往伴随着神经网络深度的加深，以获取具有更强的表达能力与提取特征能力的模型（Szegedy et al 2015, Wu et al 2019）。然而，随着网络深度叠加到达一定数目后，网络将丢失大量有价值的特征，导致模型分类的精度反而降低，这表明直接堆叠网络的方式并不合理（He et al 2016）。为解决这一问题，He 等人（He et al 2016）提出了深度残差网络（Deep residual network, ResNet）。这种网络在残差学习的引导下，引入了恒等映射，形成了残差单元，巧妙地缓解了梯度爆炸、梯度消失等由于网络层数过于深化所带来的问题，并同时保证了模型的准确率。张梦雨就曾设计研究通过在花卉数据集上对比经典 CNN 模型（AlexNet、VGGNet、GoogleNet、ResNet）识别准确率，结果显示 ResNet 准确率为最高（张梦雨 2021），这意味着 ResNet 的优势极为明显。

1.2.3 语义分割算法研究进展

语义分割（Semantic segmentation），即给定一幅输入图像（在本研究中则是给定一幅土壤剖面的 RGB 图像），通过某种算法将其分割为多个具有实际意义的图像区域（在本研究中为各个诊断层所处区域），并给这些分割好的图像区域分别分配指定标签（在本研究中则为土壤诊断层类型标签）的过程。语义分割算法技术不仅可以对土壤剖面图像进行区域分割，同时可以对分割完成的不同区域分别赋予类型标签，因此将满足本研究中土壤诊断层识别的需求。

传统的图像语义分割算法，如基于聚类（Otsuka and Takemoto 2020）、图论（Boykov and Jolly 2001, Han et al 2009）、边缘（Yang et al 2011）、阈值（汪海洋等 2007）等的常用经典分割模型算法，均采用与传统的图像分类算法类似的特征，即图片中的颜色、纹理、边缘等，将图像分割成不同区域以进行图像分割。这种算法技术最早兴起时，主要针对早期单波段灰度图像的处理具有良好的表现，然而在

面对随后出现的 RGB 三波段彩色数据时，其输出则难以满足实际应用的需求。随着摄影成像技术与计算机硬件设备飞速发展，RGB 三波段彩色数据大量出现，并成为主流研究数据，使得图像语义分割这一过程更为复杂。而后深度学习由于可以同时处理多波段数据，为语义分割算法技术提供了有力的支撑（张鑫等 2021）。其中，在图像分类算法中性能发挥优秀的 CNN 模型被引入语义分割领域，并成为这一领域的网络架构发展基础。

全卷积神经网络（Fully convolutional neural networks for semantic segmentation, FCN）发展较迟于卷积神经网络 CNN，于 2015 年的 IEEE 国际计算机视觉与模式识别会议（IEEE Conference on Computer Vision and Pattern Recognition）正式提出（Long et al 2015）。与 CNN 网络最后阶段的全连接层不同，FCN 将其全部替换卷积层，并在输出时利用反卷积层对特征图进行上采样（Upsampling），将其恢复为输入图像的原尺寸，因此 FCN 将不再输出单个的特征向量，而是输出一个整幅像素均带有标签的图像。

经典的语义分割模型包括 FCN（Long et al 2015）、U-Net（Ronneberger et al 2015）、SegNet（Badrinarayanan et al 2017）、DeepLab（Chen et al 2018）等。基于这些模型框架，研究者们将其与各行各业的需求进行结合，形成了众多应用层面上表现优秀的分割模型，其中包括：医学影像分割模型（林志洁等 2021）、点云分割模型（赵佳琦等 2021）、遥感图像分割模型（王鑫等 2021）。

经典的语义分割模型中，为解决生物医学影像语义分割而提出的 U-Net 模型，仅进行 4 层的卷积便开始进行反卷积，其作为低层结构的出现，实现了从 0 到 1 的突破。低层结构较大的优点在于能够通过较少的数据集获得一个精度较优的分割模型，因而在数据获取较为受限的生物医学影像语义分割领域大放异彩。出于 U-Net 模型在生物医学影像语义分割领域的优秀表现，随后各种对 U-Net 模型编码器 encoder 上的细微创新接踵而来。其中在 2018 年（Zhou et al 2018），UNet++ 模型，一种嵌套 U-Net 模型结构的提出对模型的优化产生了较大的影响。这一网络模型保留了 U-Net 的一套编码器、解码器架构，创新点在于编码器、解码器两者之间加入了密集的嵌套，因而也被称为嵌套 U-Net 模型。其优势在于：在不加深网络层级的前提下，对卷积过程中不同层次进行进一步学习，使得 UNet++ 相较于 U-Net 有着更

好的细粒度分割能力（高未泽等 2022）。

正因 UNet++模型有以上的优点，且相较于 U-Net 模型，UNet++模型基于小样本数据集即可在语义层面（如本研究中的土壤层次）提取出更多的特征，并客观准确地分割多个目标，UNet++网络模型因此也被 Jiang 等人（Jiang et al 2021）运用于土壤发生层识别研究，并取得较好的研究结果，由于本研究与其同属于土壤层次识别研究，因此这一模型也被优先考虑运用于本研究（Zhou et al 2018, Micallef et al 2020, Jiang et al 2021）。

1.3 研究内容和技术路线

1.3.1 研究目的与内容

传统的土壤系统分类中，需要耗费大量且繁琐费时的实验测定土壤理化数据，并基于实验数据推断土壤剖面中所含有的诊断层类型，才可得出土壤的类型；此外整套流程需要消耗大量的土壤样品，当出现目标土体样品稀缺的情况，则难以完成准确的实验室测定。因此，本研究将采用符合本研究数据特性的深度学习网络模型，基于单反相机采集的 RGB 土壤剖面图像，以及通过土壤系统分类方法得到的土壤类型、诊断层类型等类型数据建立数据集，通过训练模型最终实现土壤类型与诊断层的智能识别，以满足识别鉴定工作中快速、高效、便捷、廉价等现实要求。具体内容如下：

（1）图像数据集的分别建立

出于土壤类型智能识别与土壤诊断层智能识别所用到的算法技术分别归于深度学习中的图像分类、语义分割两个有所差异的领域，同时又为了探究在类别深化（即从土纲深化至亚纲）后分类结果将产生何种变化，本研究将针对土壤类型识别研究，建立土纲数据集、亚纲数据集，针对土壤诊断层识别研究，建立层次数据集，共需建立 3 个数据集。由于原始土壤剖面图像数据集样本量较少，存在少量孤立样本，而且图像数据尺寸过大容易导致运算量巨大，同时为了增强模型的鲁棒性，需要对 3 个数据集都进行一定的数据预处理。此外土壤诊断层识别中额外需要对图像进行标注，因而其数据集也与其他两个数据集存在不同。

（2）模型的训练

深度学习中网络模型范式繁多，而其架构大多较为固定，尤其针对图像分类的网络架构而言，因其需要通过不断卷积与池化最终输出一个特征向量，导致难以修改其网络框架。因此选择合适的网络架构范式尤为重要。本文将对以往的图像分类、语义分割算法技术相关的研究进行分析，以选用高稳定性、高性能、高效率、符合本研究数据特性的深度学习网络范式进行模型训练。同时结合训练环境、样本概况进行参数的调整选择，以得到性能表现优秀的土壤类型识别模型（包括土纲层级与亚纲层级）、土壤诊断层识别模型。

（3）模型的精度评价

图像分类、语义分割算法技术相关的模型验证方式在其各自的发展过程中已经相当成熟且在众多研究中相对固定。因此，本研究所选用的精度评价指标都属于其各自领域中使用广泛且能够全面表征模型性能的指标。在进行图像分类，即土壤类型识别研究时，选用准确率、召回率等评价指标，同时构建混淆矩阵以直观表征模型在各个土壤类型中的识别能力；在进行语义分割，即土壤诊断层识别研究时，由于语义分割属于像素到像素级的算法技术，因此选用交互比、像素精度等评价指标，以评价模型的层次识别能力。

（4）误差来源分析

在通过模型验证、精度评价得到土壤类型识别模型（包括土纲层级与亚纲层级）与土壤诊断层识别模型的各项评价指标、验证结果后，本研究将根据研究区土壤特性、图像数据集数据组成及各个类别的土壤与诊断层特征，参考研究区内土壤学科领域的其他相关研究，并结合深度学习网络模型的不同特性，对模型误判情况进行探究。最后，本研究还将对于在类别深化（即从土纲深化至亚纲）后模型总体精度误差发生的变化做出分析并解释，为后续土壤类型、诊断层的智能识别研究提供经验参考。

1.3.2 技术路线

本研究的技术路线如图 1-1 所示，在前期的数据准备、文献查阅工作积累的研究基础上，对原始土壤剖面图像数据集进行一定的数据预处理工作，形成土纲数据集、亚纲数据集、层次数据集共 3 个数据集，运用深度学习网络范式，分别训练得

到土壤类型识别模型（包括土纲层级与亚纲层级）、土壤诊断层识别模型，随后分别进行模型验证、精度评价，并综合研究区已有研究进行误判分析，最后对研究结果进行总结归纳，同时对研究的不足之处进行深刻思考以对后续相关研究工作提供经验建议。




图 1-1 技术路线图

Fig. 1-1 Technology roadmap

2 研究数据与方法

对于图像深度学习而言，模型最终性能表现如何，很大程度上取决于输入网络结构的图像数据的质量。这其中包括数据样本的大小、图像内部对象的复杂程度、种类之间的差异性及其在图像上的表达能力等；同时，在图像预处理时，对原始数据的适应性操作也将对模型的最终表现有着或多或少的影响。因此，本章将详细介绍原始采样点各项信息的概况，包括采样点位置分布及数量分布、土壤层次的理化性质统计等及其在图像上对应的表现。本章中，2.1 节主要描述研究区剖面采样点各项信息的概况，2.2 节主要结合图像对本研究所采用数据集进行描述。

2.1 研究区土壤采样点总览概况

本研究中所采用的土壤类别、诊断层信息以及土壤剖面图像均来源于《中国土系志·湖北卷》（王天巍 2017）与《中国土系志·江西卷》（王天巍和陈家赢 2021）。数据来源中土壤类别信息均依据《中国土壤系统分类检索（第三版）》（中国科学院南京土壤研究所土壤系统分类课题组和中国土壤系统分类课题研究协作组 2001）检索至亚纲。

采样点的位置与数量分布以及各种理化性质会受到研究区内气候、地貌地形、地质运动、成土母质、植被、人为活动等的成土因素的影响。研究区包括鄂（湖北省）、赣（江西省）两省全省范围地区，地处北纬 $24^{\circ}29' \sim 33^{\circ}20'$ ，东经 $108^{\circ}21' \sim 118^{\circ}28'$ 。两省均处于亚热带湿润季风气候，水、热资源丰富，满足多种农作物种植条件，区域内大部分耕地可以实行一年两熟或三熟的种植制度。地貌类型齐全，既有江汉平原位于境内，又有湖北西部的云贵高原以及秦岭山系的小范围区域，还有江西南部的丘陵地区，这与土壤的形成与分布关系较为密切。两省成土母质包括碳酸盐岩类、岩浆岩类、酸性结晶岩类、石英岩类等的风化物以及第四纪地层红黏土等，分布较为复杂。区域内的成土过程包括潜育化、腐殖化、耕种熟化、氧化还原、黏化过程等。

2.1.1 土纲及其亚纲采样点分布概况

原始图像数据集中含有新成土（Primosols）、富铁土（Ferrosols）、淋溶土

(Argosols)、人为土 (Anthrosols)、雏形土 (Cambosols) 共 5 个土纲, 正常新成土 (Orthic Primosols)、人为新成土 (Anthric Primosols)、湿润富铁土 (Udic Ferrosols)、干润富铁土 (Ustic Ferrosols)、湿润淋溶土 (Udic Argosols)、常湿淋溶土 (Perudic Argosols)、水耕人为土 (Stagnic Anthrosols)、湿润雏形土 (Udic Cambosols)、潮湿雏形土 (Aquic Cambosols)、常湿雏形土 (Perudic Cambosols) 共 10 个亚纲。一共有 331 个剖面。各个剖面的地理位置分布如图 2-1 所示。各类别中剖面的数量如表 2-1 所示。

从采样点总体地理位置分布上看, 湖北省的采样点多集中分布于省内东南部分与正北部分区域, 主要受限于湖北省西部的高山地貌地形; 而江西省的采样点则较为均匀地分布于省内各个区域。从采样点类别地理位置分布上看, 湖北省内人为土与雏形土采样点集中于省内东南平原区部分, 淋溶土与新成土采样点集中于省内正北部的丘陵、高山部分; 两省的富铁土采样点基本位于江西省内, 江西省的人为土采样点则多集中于鄱阳湖湖积平原附近的耕作区。




图 2-1 各类别中剖面采样点分布图

Fig. 2-1 Distribution of soil profile sampling points in each category

由于研究区内土壤资源分布不均，每个类别中剖面采样点的数量分布也无法保证均匀。表 2-1 已按照剖面数量升序进行排列，从少至多依次分别是新成土、富铁土、淋溶土、人为土、雏形土。从亚纲层级的数量分布上看，人为新成土、干润富铁土、常湿淋溶土、常湿雏形土共 4 个亚纲类别中仅有 1 个或 4 个剖面采集点，与其他亚纲类别中的采集点个数相差较大，从亚纲的前缀描述来看，即可得出，这是研究区内雨水丰富，因而土壤水分较多所导致；土纲为人为土的亚纲中仅有水耕人为土这一个类别，这是因为研究区中人为土多分布于长江流域、鄱阳湖湖积平原内，水资源极其丰富，水耕条件极易满足。

表 2-1 各土壤类型中剖面数量

Table 2-1 Number of soil profiles in each category

土纲 Order	亚纲 Suborder	剖面数量 Number of profiles	总量 Total
新成土 Primosols	正常新成土 Orthic Primosols	22	23
	人为新成土 Anthric Primosols	1	
富铁土 Ferralsols	湿润富铁土 Udic Ferralsols	24	25
	干润富铁土 Ustic Ferralsols	1	
淋溶土 Argosols	湿润淋溶土 Udic Argosols	64	65
	常湿淋溶土 Perudic Argosols	1	
人为土 Anthrosols	水耕人为土 Stagnic Anthrosols	89	89
雏形土 Cambosols	湿润雏形土 Udic Cambosols	96	129
	潮湿雏形土 Aquic Cambosols	29	
	常湿雏形土 Perudic Cambosols	4	
总计 Total			331

2.1.2 采样点中土壤诊断层分布及信息统计

土壤诊断层按照其所在单个土体中出现的位置上下而可区分为诊断表层与诊断表下层。研究区内采样点的土壤诊断层数量分布如图 2-2 所示。




图 2-2 诊断层的数量分布

Fig. 2-2 Distribution of the number of diagnostic horizons

诊断表层是指在单个土体中位于最上部的诊断层，最容易受到人为作用影响，在研究区中涉及淡薄表层（Ochric epipedon）、水耕表层（Anthrostatic epipedon）、暗瘠表层（Umbric epipedon）、暗沃表层（Mollic epipedon）、肥熟表层（Fimic epipedon）共 5 个诊断表层。其中暗瘠表层与暗沃表层由于在研究区中样本较少，且同为有机碳含量较高的暗色腐殖质表层，二者差别仅在于盐基饱和度与土壤结构的发育比，差别较小，因此本研究选择将两者合并以进行识别。从图 2-2 中可以发现在研究区采样点中，淡薄表层分布最多，其次为水耕表层。淡薄表层属于发育较差或者较薄的腐殖质覆盖的诊断表层，是雏形土的诊断依据。水耕表层则是水耕人为土的诊断依据。这是两省土壤中雏形土与水耕人为土占地面积较大、采样较多所致。

诊断表下层是土体中物质在受到迁移、淋溶、富集等作用下，在表层下方形成的诊断层。在研究区中涉及雏形层（Cambic horizon）、黏化层（Argic horizon）、水耕氧化还原层（Hydragric horizon）、低活性富铁层（LAC-ferric horizon）、聚铁网纹层（Plinthic horizon）共 5 个诊断表下层。在研究区中存在同一个土壤层次判别为多种层次类型的情况，这一情况较为特殊，为了与实践中的判别结果一致（即实践中得到的判别结果是两种诊断层，那么诊断层识别程序也应同时给出这两种结果，以防止遗漏诊断信息），本研究选择将其作为单独的一种层次类型进行区分。从图 2-2 中可以看出在研究区的采样点中雏形层分布最多，其次分别为黏化层、水耕氧化还原层、黏化层（低活性富铁层）、低活性富铁层、水耕氧化还原层（黏化层）、聚铁网纹层。所展示诊断层的数量分布与研究区内雨水丰富、土壤偏酸性等大环境相关。

传统的土壤诊断层分类方法，要求实验人员在野外调查时记录土壤层次的形态学描述，回到实验室环境后通过对采集的土壤样品进行实验分析以得到这些层次的数字化的理化性质，再将这些数据综合野外形态学描述即可判断诊断层的类型。这些形态学描述与理化性质中有部分可以在 RGB 图像上有所表征，其中包括形态学描述中的土壤颜色等以及理化性质中的土壤机械组成、游离铁、土壤有机碳含量(SOC)等。其中土壤颜色对应于图像中 RGB 三个波段的数值；机械组成在土壤上表现为质地等情况，在图像上表现为纹理等；游离铁主要在低活性富铁层的诊断中起到作用，在图像上表现为土体颜色是否较红；SOC 含量在区分淡薄表层与其他诊断表层时能够发挥作用，在图像上表现为土壤颜色较深，典型有样本点中的暗瘠表层和暗沃表层。

Munsell 颜色系统可通过色调（Hue）、明度（Value）、彩度（Chroma）等多个维度对颜色进行描述。土壤系统分类习惯基于色调进行判别，此外，考虑到研究区土壤往往较为湿润，土壤润态颜色将更适合反应研究区土壤的实际情况，因此本文主要对土壤在润态时的色调进行统计，如表 2-2 所示。从表中可以看到，所有诊断层中，颜色位于 7.5YR 色调区域的最多，其次是位于两边的 10YR、5YR 和 2.5YR，色调分布在其他区域的较少。值得注意的是所有出现的色调中，偏为蓝绿的 10G、10BG、5PB 仅出现在水耕表层与水耕氧化还原层中，而低活性富铁层中的主要色调为 5YR 及更红的色调。

表 2-2 各诊断层中润态色调数量分布情况

Table 2-2 Distribution of hue (moist) of each category of diagnostic horizons

润态色调 诊断层	5R	7.5R	10R	2.5YR	5YR	7.5YR	10YR	2.5Y	5Y	7.5Y	10G	10BG	5PB	总计
淡薄表层	1	1	3	27	47	85	41	2		1			1	209
水耕表层				1	9	18	45	3	3			1		80
暗瘠、暗沃表层				2	3	4	2							11
雏形层			5	22	25	56	31	3	1					143
黏化层		2	1	19	28	24	10							84
水耕氧化还原层				3	7	18	40	2	3		2	2		77
黏化层（低活性富铁层）				6	7	2	1							16
低活性富铁层			1	2	5		1							9
总计	1	3	10	82	131	207	171	10	7	1	2	3	1	629

样本数据中采用美国农业部 USDA 分级标准，划分为黏粒（ $<0.002\text{mm}$ ）、粉粒（ $0.002-0.05\text{mm}$ ）、砂粒（ $0.05-2\text{mm}$ ），各诊断层机械组成的统计信息如图 2-3 所示。值得注意的是，黏化层、黏化层（低活性富铁土）的黏粒含量普遍偏高，水耕表层、水耕氧化还原层的粉粒含量显然高于其他诊断层。




图 2-3 各诊断层的黏粒、粉粒、砂粒含量均值

Fig. 2-3 Mean values of clay, silt, and sand content of diagnostic horizons

土壤化学属性中游离铁含量与 SOC 含量的统计信息如图 2-4 所示。从中可以明显地看出：1）低活性富铁土中游离铁含量高于其他诊断层；2）诊断表层的 SOC 含量高于诊断表下层；3）暗瘠、暗沃表层的 SOC 含量高于其他诊断表层。




图 2-4 各诊断层的游离铁、SOC 含量均值

Fig. 2-4 Mean value of free iron and SOC content of diagnostic horizons

研究区内主要的土壤类型与诊断层之间的数量关系如图 2-5 所示，可见雏形土中雏形层与淡薄表层分布较多，而低活性富铁层与黏化层（低活性富铁层）仅出现在富铁土中；水耕表层与水耕氧化还原层仅出现于人为土中；黏化层大量分布出现于淋溶土中。这是因为在土壤系统分类中这些诊断层都是属于其各自土纲的检索条件。而新成土中基本都是诊断表层的原因是新成土土层往往较薄，尚未发育出诊断表下层。




图 2-5 诊断层与土壤类型的数量关系

Fig. 2-5 Quantitative relationship between diagnostic horizons and soil types

2.2 图像数据集

2.1 小节主要介绍的是采样点的位置与数量分布以及诊断层的各种数据统计信息等，为了从图像上直观地观察到土壤类型之间与土壤诊断层类型之间的差异，2.2 小节将结合图像对研究数据做进一步的介绍。

土壤剖面图像是成书过程中在野外调查时使用尼康数码单镜反光相机（型号：D90）拍摄，镜头为尼康 AF-S DX 尼克尔 18-105mm f/3.5-5.6G ED VR，按照《野外土壤描述与采样手册》（张甘霖和李德成 2016）进行剖面拍摄。由于在拍摄时针对一个剖面拍摄了多张照片，这些照片之间存在着拍摄角度、光照强度等或大或小的不同，其中甚至会因为相机的参数不同而出现色调上的较大差异，如图 2-6 所示，因此本研究在数据处理时对其进行了保留，用以提高模型的泛用性。



图 2-6 同一土壤剖面不同相机参数下的图像差异

Fig. 2-6 Image differences in the same soil profile with different camera parameters

2.2.1 土纲及亚纲原始数据集

外业调查中对于一个剖面拍摄留有多张照片，因此各土壤类型中的原始图像数量与表 2-1 有所不同，如表 2-2 所示。由表 2-2 可知人为新成土、干润富铁土、常湿淋溶土、常湿锥形土等四个亚纲的图像显著少于其它纲目，因此在剔除这些孤立样本后，形成了未进行数据预处理的土纲及亚纲原始数据集。亚纲原始数据集中包含的类型如表 2-2 中的**粗体**字体所示。

为了从图像上直观地感受到不同类型的土壤剖面特征与差异，从同类型亚纲的土壤剖面图像中选出 8 幅图像作为示例，如图 2-7 所示。能从剖面图像上明显察觉到的土壤类型特征包括：

- 1) 新成土中多含有大块岩石，岩石或沉积物构造体积较高，土壤结构发育较弱；
- 2) 富铁土的色调普遍偏红，这是因为其对应的诊断层——低活性富铁层中有一条件为色调为 5YR 或者更红；
- 3) 淋溶土主要是图像纹理上的特征，其剖面中会存在一部分区域看似光滑，如同有一层胶膜覆盖其上。这是因为其对应的诊断层——黏化层、黏磐的条件中，要求土壤在黏粒的淋移淀积作用下，其黏粒胶膜、黏粒桥接物或黏粒含

量等应达到土壤系统分类中的一些含量区间；

- 4) 人为土中由于采样点均为水耕人为土，多种植水稻，其上方植被因而较为固定，为水稻根茎，同时图像的下方也多含有水面。从颜色上来看，其上方覆盖有一层颜色较深的表层土壤，这与水耕人为土对应的诊断层之一的水耕表层中的颜色要求较为吻合；
- 5) 雏形土中共性特征较少。这是因为土壤系统分类中所设定的雏形土、雏形层的相关条件，难以在图像上对应到共性特征。

表 2-3 各土壤类型中原始图像数量

Table 2-3 Number of original images in each category

土纲 Order	亚纲 Suborder	图像数量 Number of images	总量 Total
新成土 Primosols	正常新成土 Orthic Primosols	60	63
	人为新成土 Anthric Primosols	3	
富铁土 Ferosols	湿润富铁土 Udic Ferrosols	73	76
	干润富铁土 Ustic Ferrosols	3	
淋溶土 Argosols	湿润淋溶土 Udic Argosols	184	186
	常湿淋溶土 Perudic Argosols	2	
人为土 Anthrosols	水耕人为土 Stagnic Anthrosols	284	284
雏形土 Cambosols	湿润雏形土 Udic Cambosols	265	369
	潮湿雏形土 Aquic Cambosols	90	
	常湿雏形土 Perudic Cambosols	14	
总计 Total			978




图 2-7 土壤剖面图像样本示例

Fig. 2-7 Soil profile sample images

2.2.2 层次原始数据集

层次原始数据集的处理与土纲及亚纲原始数据集的初始数据筛选过程类似，对孤立样本进行了剔除。但需要注意的是，进行诊断层识别时，输入图像为一整张土壤剖面图像，为了尽可能地保留更多的层次信息，进行孤立样本剔除时不是去除整张图像，而是在土壤层次信息中去除掉孤立的层次信息，以在后续的图像标注过程中忽略对孤立层次的标注，这样图像中的其他层次信息被保留下来。通过这种方式剔除的层次信息包括肥熟表层、水耕氧化还原层（黏化层）与聚铁网纹层。

同样，由于野外调查中对于一个剖面拍摄留有多张照片，各诊断层类型中的对应图像张数与图 2-2 所示的剖面对应的各个诊断层个数有所不同，纵坐标的单位也因此不同，如图 2-8 所示。经统计，在原始图像上共有 1817 个原始层次可供训练。




图 2-8 诊断层对应的图像数量分布

Fig. 2-8 Distribution of the number of images corresponding to the diagnostic horizons

为了从图像上直观地感受到不同类型的土壤诊断层特征与差异，对原始土壤剖面图像进行裁剪，从同类型不同剖面的土壤诊断层中选出较为典型、相互之间具有一定差异的 6 张方形图像片段作为示例，如图 2-9 所示，需要注意的是这并不是语义分割中的实际操作，仅用作展示。在原始数据本就因拍摄条件不同而具有一定差异的条件下，可以看出诊断层在图像中表征出的共性特征较少，难以确定诊断层的类别归属，尤其是淡薄表层与雏形层。通过人眼能察觉到的土壤诊断层图像特征包括：

- 1) 水耕表层表现出的颜色往往较黄或较灰，且由于其受水耕搅拌而出现有糊泥化的视觉表征；
- 2) 水耕氧化还原层表现出的颜色同样往往较黄或较灰，且其具有明显的氧化还原特征，以锈纹锈斑为主；
- 3) 暗瘠、暗沃表层表现出的颜色普遍偏暗；同时其内部根系较多，这与其有机碳含量较高互为因果；
- 4) 低活性富铁层、黏化层（低活性富铁层）表现出的颜色往往偏红。

虽然以上诊断层具有这些共性特征，但必须承认的是其他诊断层中个别样本也有类似的特征表现。因此，仅以人眼直接对原始图像进行区分，容易发生识别错误，需要运用网络模型对图像进行卷积以获得更清晰的特征，从而高效地提取出计算机可以理解的图像特征，并最终实现快速而准确的智能识别。




图 2-9 土壤诊断层图像示例

Fig. 2-9 Example images of soil diagnostic horizons

2.3 数据预处理

2.3.1 图像裁剪与压缩

即使是使用相同的单反相机，由于光线、位移等各物理条件的变化，导致其拍摄得到的相片的图像尺寸也并不会总是一致的。在深度学习网络模型训练过程中，往往需要保证输入的图片大小一致，同时为了尽可能地提高模型训练效率，在正式开始模型训练前需要对原始图像进行裁剪与缩放等一系列操作。

在对原始图像进行概览时，注意到部分的原始图像中包含了土坑两侧的立面以及底面、采样工具、工作人员部分入镜等干扰因素，如图 2-10 左图所示，因而图像质量参差不齐。为了剔除这些干扰因素，同时保留地下水、地表植被等可以在类型识别中发挥作用的内容，并保证剖面尽可能完整地出现在图像中，测试筛选出了 7:5 的图像纵横比对原始图像进行裁剪，裁剪结果如图 2-10 右图所示。统一图像纵横比，是为了减少在压缩过程中引起的失真问题。




图 2-10 裁剪规则示意图

Fig. 2-10 The rule of clipping

在对原始图像进行裁剪后，根据计算机内存配置等硬件条件，本研究将土纲原始数据集与亚纲原始数据集、层次原始数据集的图像分别缩放为宽 533 像素×高 746 像素与宽 256 像素×高 256 像素备用。

2.3.2 数据增强

深度学习往往需要大量的数据以训练得到一个性能优秀的模型。数据增强则常常被用于解决数据量不够的问题。通过数据增强扩展原始图像数据集，得到的变换后的数据可以显著增加训练图像的多样性。这对于预防模型的过拟合和提高图像分割的性能是极为重要的（Zhou et al 2018, 孙红等 2021, 左仁广等 2021）。

本研究考虑了在野外使用普通数码相机拍摄时出现的各种情况、剖面图像的特征以及原始数据集的特征，在数据增强上采用了以下几种方式：

- 1) 移位、旋转：考虑到研究人员在野外拍摄时难以做到完全地竖直拍摄以及容易发生抖动等情况，数据增强将偏移百分比限制在 5% 以内，角度限制在 5° 以内。
- 2) 翻转：剖面图像均为地表植被在顶部，自上而下拍摄，因此只考虑水平翻转。
- 3) 调整亮度：考虑到拍摄时光照条件不一致，适当调整亮度，模拟不同太阳光强度。

数据增强的前后变化如图 2-11 所示。没有考虑增加噪声扰动是因为本研究认为目前相机技术已经相当成熟，很难出现椒盐噪声与高斯噪声大范围覆盖的情况；而对于没有考虑增加颜色色调变换的处理，是因为在研究数据中本就存在大量图像出现了类似于图 2-6 的色调变换。




图 2-11 增强前后的剖面图像

Fig. 2-11 Soil profile images before and after augmentation

通过对所有图像随机应用不同的移位、旋转、亮度调整值，以及随机进行水平翻转，最终得到了土纲数据集中 5 类土纲每类 399 张共 1995 张训练集图像、5 类土纲每类 171 张共 855 张测试集图像以及亚纲数据集中 6 类亚纲每类 371 张共 2226 张训练集图像、6 类亚纲每类 159 张共 954 张测试集图像，层次数据集中 2110 张训练集图像、900 张测试集图像。训练集与测试集数量比均为 7:3。

需要注意的是土纲数据集与亚纲数据集中各类别图像数量通过数据增强以达到一致。但由于层次识别研究过程中无论是数据增强过程中还是模型训练过程中输入图像均为整幅图像，同时图像中所含各类诊断层数量并不一致，因此难以通过数据增强以使得诊断层样本之间均衡，因此，数据增强的方式是将每个剖面的图像均加强至 10 张，这与 jiang 等人（Jiang et al 2021）的研究类似。由于无论是训练过程还是测试过程都需要每个类别中都有数据以完成相应工作，训练集与测试集划分过程中保证了每个数据集中都包含了所有的类别。

2.3.3 图像标注

对于语义分割算法，图像标注是训练语义分割这一类监督模型的必要步骤（Ma et al 2017）。在这一步骤中所有的诊断层根据已有的剖面描述，通过 Labelme 软件包（Russell et al 2008）进行人为手工划定，流程效果如图 2-12 所示。图像标注的输入图像是经过图像裁剪、缩放以及数据增强后的图像，如图 2-12 左图所示。本研究总共需要对 2910 张图像进行图像标注。

Labelme 软件包是一个广泛用于图像标注的 Javascript 开源工具。该工具可以自动扫描导入文件夹及其树型目录中的所有 jpg 图像，并且可以自由创建、修改、删除每张图像中的标注信息，最终在图像路径下输出同名的 json 文件。将这些通过 Labelme 形成的 json 文件转换为 VOC（Visual Object Classes）数据集格式，即可用于网络模型的训练输入。VOC 数据集默认要求有 3 个子文件夹目录，分别是 ImageSets 目录、JPEGImages 目录、SegmentationClass 目录。ImageSets 目录下保存有 train.txt、test.txt、val.txt 文件，即训练集、测试集、验证集中的所有图像的文件名信息汇总。由于本研究数据量受限，不设置验证集，因此 val.txt 中目录为空。JPEGImages 目录下存储着所有的输入图像，如图 2-12 左图所示。SegmentationClass

目录下则存储着人工标注后的结果图像,如图 2-12 右图所示,图片内黑色区域代表背景区域,即用户没有进行标注的区域,红色与绿色区域分别代表标注的诊断层区域(红色代表淡薄表层,绿色代表锥形层),文件夹内所有图像使用同一套颜色体系,即文件夹内所有图像中红色区域均代表淡薄表层。

划定过程中尽量避免划入表层中垂下的植物叶片。层次之间的具体边界参考其清晰的剖面原图进行划定,层次过渡较为模糊的根据剖面深度信息通过一根直线进行划定。




图 2-12 图像标注流程效果示意图

Fig. 2-12 The processing and effect picture of image labeling

2.4 深度学习算法

2.4.1 ResNet

正如本文 0 部分对于图像分类算法的介绍,在一定范围内加深卷积网络,模型精度会随之上升,然而单纯的增加 CNN 网络卷积层到超过一定深度,模型反而会出现梯度爆炸或梯度消失的现象,导致其精度将不升反降。这是因为网络层数越多,训练参数将会成倍地增多,尤其在过深的网络反向传播梯度的过程中,网络的训练也会因此愈加困难,甚至会出现梯度爆炸或消失的严重问题。ResNet 就是因为解决了这一问题而被广泛使用,乃至后续出现的大部分网络都是基于这一网络进行创新的,何凯明提出这一网络的论文其引用次数也一直居于人工智能领域的最前列(He et al 2016)。

ResNet 使用了一种捷径 shortcut 结构,将低层网络特征 x 直接映射于高层网络

中，也就是增加了一个恒等映射。假设网络结构中有一段输入为 x ，输出为 $H(x)$ ，shortcut 结构会将初始的学习目标 $H(x)$ 替换为残差 $H(x)-x$ 。通过这样的结构，整个网络只需要对残差，即输入、输出差别的一部分进行学习（苏赋等 2019）。这样就极大的简化了学习对象并降低了难度。随着层级的加深，如果权重层未学习到特征，即 $F(x)$ 为 0 时，则 $H(x)$ 就是一个恒等映射(identity mapping)。

ResNet 的基本单元是残差单元即残差块，如图 2-13 所示。残差单元由两个部分组成：一个是线性直接映射 $x \rightarrow x$ ，另一个为非线性映射即残差 $F(x)$ 。残差单元在网络中表现是由卷积层 Convolution layer、批处理归一化层 Batch normalization layer (BN layer) 与非线性激活函数 ReLU 组成（赵志成等 2020）。BN layer 将卷积层输出调整满足正态分布，使得激活输入值分布于 ReLU 较为敏感的区域（张梦雨 2021）。而 ReLU 部分则是加入非线性因素，以处理线性不可分的问题（赵鑫龙等 2020）。ResNet 残差块中“+”是指矩阵值相加。




图 2-13 残差块示意图（He et al 2016）

Fig. 2-13 Diagram of residual block

多个单元产生了多个旁路的支线将输入的信息绕道直接传到输出，一定程度上保持了信息的完整性，因而减缓了最终错误率因为网络过于深化而愈发增大的趋势。

本研究中图像分类所采用的网络结构如图 2-14 所示。可见网络中除了多个残差块外，在网络的起始有一层 7×7 卷积与最大池化，这是为了快速缩小输入数据量，并调整为后续残差块所需要的尺寸大小以及通道数。而整个网络结构的末尾还有一层平均池化以及激活函数为 Softmax 的全连接层。这是为了将最后的输出转换为一个列向量并降低至规定的土纲或亚纲类别数量。




图 2-14 ResNet 网络架构

Fig. 2-14 Structure of ResNet

本次研究选择了 ResNet-18 网络结构，18 代表了网络层数。图中残差块组合中共有图 2-13 所示的残差块共 8 个块，即 16 个卷积层，再加上起始的卷积层以及末尾的全连接层，即 18 层网络。

2.4.2 UNet++

正如本文 1.2.3 部分对 UNet++ 的优点阐述以及其对本研究中层次识别任务的适应能力分析，本研究将采用 UNet++ 范式对层次数据集进行训练。UNet++ 范式架构如图 2-15 所示。




图 2-15 UNet++ 网络架构

Fig. 2-15 Structure of UNet++

正如本文 1.2.3 中对 UNet++ 的介绍，其对于 U-Net 网络架构的创新之处在于图 2-15 中绿色部分。其左侧是编码器路径（图 2-15a），右侧为解码器路径（图 2-15b）。编码器路径中对原始图像进行了四次的下采样，每层进行卷积、激活函数操作，并进行最大池化。卷积核尺寸为 $3 \times 3 \times 3$ 。随着层数向深发展，每层特征图的分辨率逐渐变低，图像逐渐模糊、抽象，通道数逐渐增多，空间定位特征等细节信息逐渐损失，但提取了更多的图像特征。不同于 CNN，UNet++ 的解码器路径利用特征图进行对应的四层上采样，恢复被压缩的图像直至还原，并输出分割的图像。为了更多地融合浅层特征信息，还通过跳跃连接将对称的编码器与解码器路径上的特征图进行通道合并（图 2-15 中黑色虚线部分），将下采样时提取到的特征直接传递到上采样中，帮助补充了更多的细节。

以上为 U-Net 网络结构，即图 2-15 中黑色部分的主要运作方式。UNet++ 作为 U-Net 的变种、创新架构，通过更为密集的嵌套跳跃路径（图 2-15 中绿色虚线部分，即图 2-15c）将编码器与解码器路径上的特征图进一步连接。这样 L1~L5 中所有的结点都能够通过每一层的上采样连接起来，更多的特征信息因此被融合起来。嵌套跳跃路径也用于将输入图像的信息从编码器路径中的每个节点传输到解码器路径，可以使用连接来减少解码过程中的信息损失，这使得解码器路径生成的结果在语义层面上（即本研究中的土壤层）上更接近于输入图像。从多个解码器分支上采样还原生成的原始图像（图 2-15d 中的 4 个图像），是多个级联跳越路径的结果。最后对来自多个解码器分支的所有输出图像进行平均，以得到一个最终的分割结果。

对称的编解码网络结构，通过镜像折叠外推缺失的图像信息，对输入图像的语义信息进行补充，跳跃连接的方式可以将编码器、解码器中的特征图直接进行融合，因此可以更高效地获取并汇总图像中蕴含的深层次细节信息和表露的浅层语义信息。

2.5 评价指标

基于前人研究，对于图像分类相关研究中，准确率与召回率这两个指标使用最为广泛（Chen et al 2022，曹润芝等 2022，邱云飞等 2022）；在语义分割相关研究中，均交并比与像素精度则使用最为广泛（Liu et al 2021，Zhao et al 2021，高未泽等 2022）。因此，本研究也将应用准确率、召回率于土壤类型识别研究、均交并比

与像素精度于土壤层次识别研究。

2.5.1 准确率

准确率 ACC 是图像分类中的评价指标,是指应用训练后的模型对图片数据集进行分类时,正确的样本总数占总体样本数的比例,是一种从总体上判断模型精度的评价指标,计算方式如等式 2-1 所示。

$$ACC = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-1)$$

TP (True Positive)是指模型预测为正例(Positive, P),实际也是正例的个数,因此预判正确(True, T)。 FN (False Negative)是指模型预判为负例(Negative, N),实际是正例的个数,因此预判错误(False, F)。以此规律可以推出 TN 代表了预测为 N 但是正确判断为 N 的个数, FP 代表了预测为 P 但是错误判断为 N 的个数。

2.5.2 召回率

召回率 R (Recall ratio) 是图像分类中的评价指标,是指一类样本中预测正确的样本个数占此类总样本数量的比值,计算方式如等式 2-2 所示。

$$R = \frac{TP}{TP + FN} \quad (2-2)$$

通过召回率可以量化模型在一类样本中的预测能力。

2.5.3 均交并比

语义分割中,为了评估模型,手动圈定的层次被认为是真实值,以验证模型的性能。交并比 IoU (Intersection over Union) 与均交并比 MIOU (Mean Intersection over Union) 是语义分割中的评价指标。其中交并比 IoU 是图像中像素的真实值与预测值的交集与两者并集之间的比例,计算方式如等式 2-3 所示。而均交并比 MIOU 则是一个类别中 IoU 的均值,计算方式如等式 2-4 所示。这一指标主要量化预测结果和人工划定的层次之间的相似性。

$$IoU = \frac{P \cup G}{P \cap G} \quad (2-3)$$

$$MIOU = \frac{\sum IoU_i}{n} \quad (2-4)$$

等式 2-3 中 P 指模型的预测， G 指人工划定区域， $P \cup G$ 指 P 和 G 的并集面积， $P \cap G$ 指 P 和 G 的交集面积。等式 2-4 中 $\sum IoU_i$ 指某一类层次的 IoU 总和， n 为类别中样本个数。

2.5.4 像素精度

像素准确率 PA (Pixel Accuracy) 是语义分割中的评价指标，是正确分割的像素与图像总像素之间的比例，反映了模型的准确性。计算方式与等式 2-1 类似，如等式 2-5 所示。

$$PA = \frac{TP + TN}{TP + FP + TN + FN} \quad (2-5)$$

公式中 TP、TN 等表示的意思与等式 2-1 类似。但此时其统计于像素层面上，而非图像的层面上。

3 基于 ResNet 的土壤类型识别

3.1 土壤类型识别模型

3.1.1 实验设备与环境配置

出于图像分类的两个数据集较大，使用的计算机内存为 64GB。操作系统为 Windows 10 操作系统，CPU 为 Intel Xeon E5-2620 v4，2.10GHz 主频，16 核 32 线程。基于 Python V3.8 语言，并辅以 PyCharm 和深度学习框架 Tensorflow V2.3。

3.1.2 参数设置

ResNet 的参数设置包括激活函数 (Activation function) 与损失函数 (Loss function) 的选择、学习率 (Learning rate, LR)、批量训练大小 (Batch size)、总迭代次数 (Epoch) 等。

激活函数的引入是为了避免模型过于线性，以增强模型的拟合能力。在 ResNet 中往往采用 Relu 函数作为其激活函数，其属于一种分段函数，表达式如等式 3-1 所示。Relu 与其它激活函数相比，不涉及指数运算，在反向传播计算误差梯度时也不涉及除法，计算开销较低，此外，Relu 函数其优点在于正区间内解决了梯度消失的问题，在负区间内缓解了过拟合的问题，可更快地完成特征提取，同时计算与收敛的速度更快。

$$f(x) = \max(x, 0) = \begin{cases} 0, & x < 0 \\ x, & x \geq 0 \end{cases} \quad (3-1)$$

损失函数中所谓的损失是指模型预测值与给定真实值的差值。这一函数在神经网络中主要用于计算误差，并在网络中通过反向传播逐层向上传递直至第一层，并根据误差的变化自动调整更新所有的权重值。ResNet 所使用的是交叉熵损失函数 CE (Cross entropy)。表达式如等式 3-2 所示。损失函数值越小，表明函数拟合越接近真实值。

$$H(y_-, y) = - \sum (y_- \times \ln y) \quad (3-2)$$

式中 $H(y_-, y)$ 是指损失函数值， y_- 是指真实值的概率分布， y 是指预测结果的概率分布。

学习率与模型的损失函数下降速度有关，提高 LR 可以使得模型收敛加快，但是当 LR 过大时，可能使得模型参数在某一步中越过最优值。在本研究中，模型的 LR 会根据测试集准确率判断训练时有无进展，并逐步减小 LR，以使得模型性能更强，初始值为 0.001。

在实际训练模型时，往往很难一次就将全部的数据输入网络中，这对于计算机的内存要求很高，而将数据集中的数据按照固定的大小一批一批地输入网络中为普遍做法。批量训练大小则是每批次送入训练模型的样本数量，从而优化计算机内存使用，同时它也影响了模型权重的优化程度与速度。本研究根据计算机内存大小设置为 32。

总迭代次数是模型总览所有样本数据的次数。这一数值往往根据 Loss 曲线进行确定，在曲线趋于平缓后则表示训练的模型接近于训练集能达到的精度最高的模型。根据多次模拟训练，本研究选取 150 作为迭代次数。

3.1.3 训练过程

分别应用前文所述的 ResNet-18 网络对预处理以及数据增强后的土纲、亚纲层级上的土壤剖面图像数据集进行训练，模型的准确率随着训练中迭代次数逐渐增加的变化如图 3-1 所示。




图 3-1 土纲 (a)、亚纲 (b) 数据集准确率变化曲线

Fig. 3-1 ACC curves of the dataset of order (a) and suborder (b)

图 3-1 中训练集准确率都是较为平稳地上升，在土纲数据集中第 119 次迭代后稳定在 99% 以上，亚纲数据集则提前至第 93 次迭代后。

而图 3-1 中测试集准确率曲线在上升过程中波动幅度都较大。这是由于在训练前期，模型的各层网络权重都是未进行充分调整的，导致了准确率极不稳定。随着训练次数逐渐增多，伴随误差反向传播以及权重参数更新，准确率会在后期趋于平稳。土纲数据测试集在第 123 次迭代后首次达到 90% 并在第 134 次迭代后保持平稳在 $90\% \pm 1\%$ ，在第 142 次迭代时达到最高值 90.88%。亚纲数据测试集则是在第 103 次迭代后稳定在 $92\% \pm 1\%$ ，在第 140 次迭代时达到最高值 93.71%。训练最终得到的模型也就是训练集以及测试集准确率最高的模型，因此分别取土纲数据集第 142 次迭代时、亚纲数据集第 140 次迭代时产生的模型。

3.2 结果分析

针对最终得到的模型，统计其在训练集以及测试集中的混淆矩阵以判别模型较难辨别的土纲或亚纲类型。由于两个模型在训练集中准确率均为 100%，这意味着训练集中所有的数据均判断正确，因此不再展示其混淆矩阵。同时在 CPU 的支持下，输入图像对模型进行验证过程中，每张图像的预测时间平均为 0.14 秒。

3.2.1 土纲数据集

土纲测试集模型混淆矩阵如图 3-2 所示。图中括号内为召回率。




图 3-2 土纲测试集模型混淆矩阵

Fig. 3-2 Confusion matrix for the order validation set model

5 个土纲，每个土纲 171 张图像，共 855 张测试集图像中判断正确 777 张、判错 78 张，总体准确率为 90.88%。其中新成土仅 2 张判错为雏形土，召回率达到 0.99，模型预测能力最好；其次，富铁土（0.94）与人为土（0.93）均表现良好，且都有错判为雏形土（富铁土 5 张，人为土 10 张）与淋溶土（富铁土 5 张，人为土 2 张）的情况；再次为淋溶土，召回率为 0.90，9 张错判为雏形土、5 张为富铁土、4 张为人为土；模型表现较差的为雏形土，召回率仅为 0.79，15 张错判为淋溶土、11 张为人为土、6 张为新成土、4 张为富铁土。

3.2.2 亚纲数据集

亚纲测试集模型混淆矩阵如图 3-3 所示。图中括号内为召回率。




图 3-3 亚纲测试集模型混淆矩阵

Fig. 3-3 Confusion matrix for the suborder validation set model

6 个亚纲，每个亚纲 159 张图像，共 954 张测试集图像中判断正确 894 张、判错 60 张，总体准确率为 93.71%。6 个亚纲中潮湿雏形土与正常新成土所有图像均判断正确。其次为湿润富铁土与湿润淋溶土，召回率分别为 0.95、0.93，其中湿润富铁土中 4 张被错判为湿润淋溶土，错判为正常新成土与湿润雏形土的各 1 张；湿润淋溶土中 7 张错判为湿润雏形土、4 张错判为湿润富铁土。再次为水耕人为土，召回率为 0.90，其中 9 张错判为潮湿雏形土、4 张错判为湿润雏形土、2 张错判为湿润淋溶土。湿润雏形土的召回率在 6 个亚纲中表现最差，为 0.82，18 张错判为湿润淋溶土、6 张错判为潮湿雏形土、3 张为水耕人为土、1 张为湿润富铁土。

3.2.3 误判分析

首先，就总体而言可以看到随着土纲细化至亚纲这一层级，总体误判的比例有所减小。这是由于亚纲作为土纲的辅助级别，添加了因成土过程中的控制因素而导致的性质差异（例如水分、岩性等），因而使得一个土纲的剖面图像中差异更少，并最终导致了误判减少。这一点从后续统计中雏形土中预判错误的剖面图像中 86.11%

的实际类型均为湿润雏形土，常湿雏形土占 8.33%，潮湿雏形土为 5.56%可以看出：正是因为细化了剖面图像，并同时去掉了仅含有小数量剖面亚纲图像的干扰，误判得以减少，从而使得雏形土细化至潮湿雏形土与湿润雏形土过程中，湿润雏形土召回率提升至 0.82，潮湿雏形土中召回率甚至达到了 1.00，并最终影响到总体误判比例。

而就单种类型而言，无论是新成土还是正常新成土的表现，均表现优秀，误判较少。在浏览这两个数据集图像后可以看出，这是由于数据集中土壤剖面大多是含有岩石的原因，使得这一类土壤较为特殊，容易被网络捕捉到特征。对于富铁土与湿润富铁土，其召回率均表现良好，而其对应的误判结果大部分均为淋溶土与湿润淋溶土，这说明富铁土中有少数部分容易与淋溶土混淆。富铁土与淋溶土在系统分类中分别是由低活性富铁层和黏化层或黏磐检索，而在数据源中鄂赣交界地区有部分的土壤剖面黏化与富铁铝化是同时进行的（牟经瑞 2016），这被认为是网络错判的原因。

对比图 3-2 与图 3-3 中的两个混淆矩阵不难发现，雏形土或湿润雏形土与其他的土壤类型之间是产生误判现象最多的种类。在雏形土的检索条件中雏形层占据着重要地位。在鄂赣地区的大环境下，雏形层的诊断条件中发挥主要重要作用为：不符合黏化层、低活性富铁层或铁铝层的相关要求。因此不难看出雏形土往往是通过一一排除后得到的类型。正因如此，雏形土或湿润雏形土数据集中图像特征多变，难以让网络捕捉到共性特征并导致了其召回率相对其他类型较低。

3.3 本章小结

本章选用 ResNet-18 网络模型对湖北与江西省内主要的土壤类型在土纲与亚纲层级上进行训练分类，探讨了人工智能算法结合土壤剖面图像应用于土壤分类领域的可行性。在训练过程中，土纲与亚纲测试数据集分别在第 142 次与第 140 次迭代达到总体准确率最高值 90.88%与 93.71%，总体准确率均表现良好，从而证明了利用土壤剖面图像进行土壤类型分类可行，同时也证明了随着分类层级的深入，总体准确率也会随之提升。

在模型训练完成后，本研究统计并获得混淆矩阵，还对类别之间出现的误判情

况进行分析，将本研究使用的图像数据集输入 ResNet-18 后，对新成土及其亚纲的分类表现最为优秀，这被认为是与数据集中的新成土大都含有岩石有关。除新成土外，其它类型的分类表现依次是富铁土、淋溶土、人为土及其亚纲，其中前两者及其亚纲有部分土壤剖面较易混淆，这被认为是与数据集部分土壤剖面黏化与富铁铝化的同时进行相关。人为土及其亚纲在图像表现上与雏形土、淋溶土较为相似导致它们之间稍易相互误判，而它们主要的差异在于图像顶部的地表植被以及图像底部的水面，这说明了在土壤类型识别过程中保留这两部分的重要性。表现最差的是雏形土及其亚纲湿润雏形土，这被认为是与雏形土往往是通过一一排除后得到的类型有关。

4 基于 UNet++ 的土壤诊断层识别

4.1 土壤诊断层识别模型建立

4.1.1 实验设备与环境配置

由于诊断层识别模型属于深度学习的一种低层模型，运算量不高，其训练基于一台内存为 32GB 的便携式计算机，基于 GPU 进行运算。其操作系统为 Windows 10 操作系统，GPU 为 NVIDIA GeForce RTX 3060 Laptop GPU，GPU 内存为 6GB。运用了 Python V3.6 语言，并辅以 PyCharm 和深度学习框架 Pytorch V1.2。

4.1.2 参数设置

RGB 三波段的剖面图以及相对应的标签图像被同时输入用于训练模型。诊断层识别模型所用的参数类型与图像分类研究中类似，其定义、设置原则及作用也较为相似，因此在本章中不再赘述。

学习率为 0.001，与图像分类研究中一样，会根据测试集准确率判断训练时有无进展，并逐步减小 LR，以使得模型性能更强。由于此次训练基于 GPU，而 GPU 内存往往较小，因此 Batch size 设置为 4。经过多次预先测试，Epoch 选定为 150。

需要注意的是损失函数的选择。图像深度学习中，若存在类型间样本数量严重失衡的问题，神经网络将着重对样本量大的类型图像学习，而忽视样本量少的类型，引起各类型数据的损失函数值相差悬殊，最终导致各类型的识别能力成偏态分布（Hossain et al 2021）。在本研究的土壤类型识别过程中，其数据集是通过数据增强以保持各类型样本之间数量均衡；而层次识别研究中由于输入图像为整幅图像，图像中所含各类诊断层数量并不一致，因此难以通过数据增强以使得诊断层样本之间均衡。这是语义分割领域容易出现的问题。解决这一问题，较为有效的方法则是调整损失函数。本研究将根据 Yeung 等人（Yeung et al 2022）的研究将 Dice 损失函数与 Focal 损失函数结合以对抗因样本严重失衡而产生的梯度消失的问题，这也将提高模型的分割识别能力。

4.1.3 训练过程

将 4.1.2 所述的参数设置应用于 UNet++网络范式，并输入通过预处理操作完成的 2910 张图片。模型训练过程中训练集与测试集的 Loss 曲线如图 4-1 所示。




图 4-1 模型训练过程中的 LOSS 函数曲线

Fig. 4-1 LOSS curves during the training of the model

在 150 个 Epoch 中模型总体上一直持续收敛状态，Loss 函数值在总体上不断下降。模型在训练和测试数据集上的损失曲线从第 1 次迭代至第 100 次迭代过程中缓慢下降，并且在第 100 次迭代至第 150 次迭代过程中趋于平缓。两个数据集的 Loss 曲线达到平稳的迭代次数大致相同，且曲线收敛过程中波动较小。此外，在训练集的 Loss 函数值在第 100 次迭代后大致稳定在 0.66 ± 0.01 ，在第 135 次迭代时为 Loss 函数值最低值 0.655；在测试集的 Loss 函数值在第 100 次迭代后大致稳定在 0.68 ± 0.01 ，在第 137 次迭代时为 Loss 函数值最低值 0.683。但需要注意的是，Loss 函数值的最低并不代表着此时模型的性能最优。

相应地，绘制训练过程中所有样本（包括训练集与测试集）不同诊断层类型的均交并比变化曲线以及总体样本（所有数据集的所有诊断层类型）均交并比变化曲线，如图 4-2 所示。可以看到在第 50 次迭代之前，模型在淡薄表层、水耕表层、水耕氧化还原层三个类型的诊断层均交并比表现较好，区分能力较高，但三者均交并比曲线相互交错、难以区分，此时三者均交并比相差不大；其次，均交并比从高至低依次是雏形层>暗瘠、暗沃表层>黏化层>黏化层（低活性富铁层）>低活性富铁层；

特别地，黏化层（低活性富铁层）与低活性富铁层在前 15 次迭代均交并比甚至为 0。第 50 次迭代至第 70 次迭代期间，淡薄表层、水耕表层、水耕氧化还原层三个类型的诊断层均交并比曲线逐渐分开，均交并比从高至低分别是水耕氧化还原层、水耕表层、淡薄表层；锥形层与暗瘠、暗沃表层以及黏化层与黏化层（低活性富铁层）均交并比曲线则两两逐渐靠近；低活性富铁层的均交并比仍然表现最差。在第 70 次迭代后淡薄表层均交并比曲线已经平稳，且与锥形层以及暗瘠、暗沃表层相交错，并逐渐低于后两者。在第 100 次迭代后所有层次以及总体样本的均交并比曲线已经平稳，在不同诊断层类型上，均交并比依次为水耕氧化还原层>水耕表层>暗瘠、暗沃表层≈锥形层>淡薄表层>黏化层（低活性富铁层）>黏化层>低活性富铁层，其各诊断层最高值分别对应是 82.98%、77.86%、73.54%、73.45%、71.79%、62.44%、61.37%、52.52%。总体样本在第 148 次迭代中均交并比达到最高，为 71.36%。




图 4-2 均交并比变化曲线

Fig. 4-2 MIoU curves

如图 4-3 所示，不同于均交并比的变化曲线以较小的波动向上收敛，各诊断层类型的像素精度的变化曲线在模型训练的前期波动幅度显然更为剧烈，但总体上其仍然遵循向上收敛的趋势，在训练后期较为平稳。其与均交并比的变化曲线相似，

均在模型训练第 100 次迭代时, 达到平稳状态。各诊断层类别上的像素精度从大至小的顺序大体上与均交并比较为相似, 为水耕氧化还原层>水耕表层>锥形层>淡薄表层>暗瘠、暗沃表层>黏化层>黏化层(低活性富铁层)>低活性富铁层。值得注意的是各个像素精度变化曲线达到平稳后的像素精度值相对均交并比更高。其各诊断层最高值分别对应是 93.71%、89.55%、88.09%、85.38%、84.79%、78.31%、76.08%、69.10%。总体样本在第 123 次迭代中均交并比达到最高, 为 82.66%。




图 4-3 像素精度变化曲线

Fig. 4-3 PA curves

在此前相关研究的网络模型训练过程中, 有部分研究选择选取最后一次迭代生成的模型作为最终模型 (Jiang et al 2021)。但本研究认为此种做法有待商榷, 难以全面发挥各评价指标的作用。正如本研究中两个评价指标均交并比、像素精度达到最高时的迭代次数并不相同, 分别为第 148 次与第 123 次迭代, 这两次迭代产生的模型应该在其各自的评价指标上均代表着最能准确识别土壤诊断层的模型, 但均不属于最后一次迭代产生的模型。为了综合发挥两个评价指标的作用, 以择出最终的模型, 本文统计了第 148 次、第 123 次迭代所产生的模型对各样本的各项指标, 如表 4-1 所示。可以发现第 123 次迭代所产生的模型无论是在标准差之和还是

MIoU+PA，均表现均优于第 148 次迭代。因此选择第 123 次迭代所产生的模型作为最终模型。

表 4-1 第 123 次、第 148 次迭代所产生模型的不同指标表现

Tabel 4-1 Different metrics of the models generated in the 123rd and 148th epoch

Epoch	第 123 次		第 148 次	
	均交并比	像素精度	均交并比	像素精度
	(%)	(%)	(%)	(%)
	MIoU	PA	MIoU	PA
淡薄表层	71.69	84.51	71.78	84.68
雏形层	73.39	86.48	73.45	86.57
暗瘠、暗沃表层	73.38	84.09	73.49	83.64
低活性富铁层	52.16	64.95	52.49	64.01
黏化层	61.03	74.85	61.29	75.25
水耕表层	77.80	89.23	77.74	89.08
水耕氧化还原层	82.86	91.90	82.88	92.33
黏化层（低活性富铁层）	62.19	74.53	62.43	73.15
所有诊断层相应指标标准差	9.41	8.48	9.29	8.86
总体样本	71.24	82.66	71.36	82.38
标准差之和	17.89		18.15	
MIoU+PA	153.9		153.7	

4.2 结果分析

4.2.1 模型验证

为了探究训练得到的模型不足之处，更直观地观察模型运行结果，本文从 5 个土纲中分别选出 4 个较为有代表性的剖面图像，作为输入图像（图像增强后的图像）输入模型，并且将人工绘制的带有标签图像与模型识别结果图像进行比较，最终展示作为示例，如图 4-4 所示。本研究根据野外描述数据进行人工绘制的标签被认为是真实、正确的层次位置与类型，但人工绘制标签需要注意的是，并非所有土壤层次之间的过渡情况都是突变、清晰或平滑的，除此之外还存在有边界渐变、模糊、波状、不规则与间断等情况，因此在这些情况下人工绘制边界将根据原始清晰的图像进行绘制，但当出现难以人眼识别边界的情况时，则会根据野外描述的层次深度信息与图像中的剖面标尺，以一根直线代替渐变、模糊的边界。




图 4-4 诊断层识别模型运行结果示例图

Fig. 4-4 Examples of diagnostic horizon identification model results

为了更直观地将结果图像与各层次的评价指标进行综合分析，将表 4-1 中最终模型的各项指标以图 4-5 的形式展示出来。




图 4-5 最终模型各诊断层的识别能力

Fig. 4-5 Identification capability of each diagnostic horizon of the final model

结合图 4-4 以及图 4-5 进行分析，基于 UNet++ 的土壤诊断层识别总体而言，其最终模型能够较为准确地识别与划分研究中所涵盖的土壤诊断层类型，均交并比为 71.24%，平均像素精度为 82.66%。因此利用语义分割网络模型进行土壤诊断层快速识别是可行的。

根据表 4-1 以及图 4-4 中，最终模型在不同的诊断层较为不同的识别能力，可以发现水耕氧化还原层与水耕表层两种诊断层在两个评价指标上表现的识别能力均为最高，在图像上两者相互间的边界以及与土坑中的水面、背景（即表层上方植被等）之间的边界亦能够较为准确的划分。

从评价指标与结果图像上分析，雏形层与暗瘠、暗沃表层与淡薄表层的识别效果则次之。其中淡薄表层即使是以较薄土层厚度出现也能被模型准确识别，如图 4-4 新成土(b)图中所示。但较为特别的是，识别结果的图像中存在有较多的、尺寸大小不一的、不规则的雏形层图像以斑块形式错误地出现在各类土壤图像中，如图 4-

4 新成土(a)(d)、富铁土(a)(d)、淋溶土(a)、人为土(c)图中所示。

基于评价指标可发现,模型对于黏化层(低活性富铁层)、黏化层、低活性富铁层的识别能力较差,其中低活性富铁层的均交并比、像素精度指标仅为 52.16%与 64.95%,远远低于其他诊断层指标。在图 4-4 中,可以明显地看出富铁土中的图像层次划分相较于其他土壤类型中的层次划分较为混乱,在富铁土(a)(d)中尤为突出,甚至较大范围地出现了不存在于其对应的人工绘制标签图像中的层次类型。而在淋溶土中,黏化层则划分识别效果较好。

值得注意的是,当土壤层次之间的边界较为模糊时,划分的效果会有所下降,这一现象在图 4-4 中的富铁土(b)(d)、人为土(c)中尤为突出。同样地,当土壤层次之间的边界极不规则时,划分的效果也会有所下降,如雏形土(d)所示。

4.2.2 误判分析

土壤诊断层识别相较于土壤类型识别难度更大,其导致误判的成因也更为复杂。同时,土壤诊断层识别作为语义分割算法的实践应用之一,相较于其他领域的语义分割应用而言,由于其自身的边界明显度就存在有渐变、模糊等情况,其边界形状也存在有间断、不规则等的情况而更具有挑战性。但总体而言,诊断层识别模型得到的结果图像仍然可以较为真实、准确地提供诊断层的类型、位置信息,为野外诊断层判别工作提供快速、高效、廉价的技术支持。

由于土壤剖面图像上部与下部往往存在着较大差异,模型在诊断层表层与诊断表下层上的识别能力也有所不同。从评价指标上看,诊断表层相较于诊断表下层更容易识别,这是因为表层土壤通常颜色较深,与腐殖化有机物的积累相关,因此与诊断表下层特征差异较大(Bridges 1993)。

对于人为土的两个重要诊断层——水耕表层与水耕氧化还原层而言,在遍历所有的模型识别结果图像后,可以发现此两种诊断层几乎并不出现在其他类型土壤中。这是因为水耕表层与水耕氧化还原层区别于其他诊断层的图像特征较为明显,正如本文 2.2.2 小节中所分析的,水耕表层与水耕氧化还原层颜色往往较黄或较灰,且由于长期水耕影响而具有糊泥化、氧化还原特征等较为强烈的视觉表征。

本文 4.2.1 小节中曾提到各类土壤剖面图像中常常会有或大或小的区域被错误

地划分为了雏形层。其原因与本文对土壤类型识别过程中雏形土的误判原因相似。雏形层在定义上是一种具有土壤结构发育的，基本上无物质淀积，无明显的黏化，带红、黄、紫、棕等颜色的土壤层次，其在鄂、赣地区中能主要发挥的条件可以概括为：1）较细的质地；2）有土壤结构发育并占土层体积较大、岩石等体积较少或彩度较下层更高、色调更红或黄；3）不符合黏化层、低活性富铁层的条件（中国科学院南京土壤研究所土壤系统分类课题组和中国土壤系统分类课题研究协作组 2001）。可以看出其特征适用范围较为宽泛，容易在其他土壤类型中误判。此外，根据在本文 2.1.2 小节中对雏形层的统计信息观察分析以及在 2.2.2 小节中对雏形层的图像上的特征观察分析，雏形层的特征都难以捕捉。

同样特征适用范围较为宽泛的是淡薄表层，其定义上是一种发育程度较差、颜色较淡或者较薄的腐殖质表层（中国科学院南京土壤研究所土壤系统分类课题组和中国土壤系统分类课题研究协作组 2001）。但由于其属于诊断表层，与诊断表下层差距较大等原因，容易被模型准确划分。

暗瘠、暗沃表层则由于颜色较暗、根系较多等适用范围较小且明显的特征，模型划分效果较好。

对于研究区鄂、赣两省的土壤而言，已有研究指出，鄂赣交界地区有部分的土壤剖面黏化与富铁铝化同时进行（牟经瑞 2016），因此研究区样本内存在有部分同属于低活性富铁层与黏化层的诊断层。本研究出于满足实际诊断需求（即在诊断层识别时，得到的结果应是两者兼有，若只得出一种类型则被认为是不全面的识别结果）而在图像标注时将这一类土壤层次标注为不同于低活性富铁层或黏化层的一类诊断层。这也对模型识别黏化层（低活性富铁层）、低活性富铁层、黏化层此三类诊断层的过程中造成了一定的干扰。同时研究区内富铁土中低活性富铁层样本较少、多数诊断层色调与低活性富铁层相近（如表 2-2 所示）也被认为是此三类诊断层对应的评价指标值相对较低的主要原因。

4.3 本章小结

在本章中，基于语义分割领域内的 UNet++ 网络模型范式训练得到土壤诊断层识别模型，用以识别和划定湖北、江西两省的土壤诊断层类型与其在剖面中位置。本

文出于土壤层次数据难以通过数据增强调整样本间数量均衡的考虑,选择将 Dice 损失函数与 Focal 损失函数结合以提高对数量较少的类型样本的识别能力。在训练过程中,综合利用了两个评价指标,选择第 123 次迭代中产生的模型作为最终模型,其均交并比为 71.24%,平均像素精度为 82.66%,精度表现良好,从而证明了利用语义分割模型进行土壤诊断层识别的可行性。

模型在不同诊断层类型上的识别能力并不相同,排序依次为水耕氧化还原层>水耕表层>锥形层>暗瘠、暗沃表层 $\approx$ 淡薄表层>黏化层(低活性富铁层) $\approx$ 黏化层>低活性富铁层。诊断表层相较于诊断表下层大多更容易识别,这是表层土壤腐殖化有机物的积累而颜色较深所致。而具体的每种诊断层根据其定义以及诊断条件在 RGB 图像上的特征适用范围是否宽泛、样本数量多少存在着识别能力上的差异。同时,研究区内部分的土壤剖面黏化与富铁铝化同时进行的特例情况对识别能力也产生了较大影响。

5 总结与展望

5.1 主要结论

本文基于深度学习中的图像分类算法 ResNet、语义分割算法 UNet++分别完成了土壤信息定量化表达和应用推广的重要基础工作——土壤类型与诊断层的智能识别；通过江西、湖北两省主要土壤类型的 RGB 剖面图像，经过剔除孤立样本、图像裁剪与缩放、数据增强、图像标注等一系列预处理后，分别输入至对应的深度学习模型，训练得到了精度表现优良的土纲与亚纲层级的土壤类型识别模型、土壤诊断层识别模型，并且采用相对应的评价指标对各个模型进行了精度评价。本文主要成果及结论如下：

（1）模型针对不同分类层级的土壤类型的识别能力差异。

本文在不同分类层级下，共建立了土纲、亚纲两个层级的土壤类型识别模型。其中土纲测试数据集在第 142 次迭代中达到总体准确率最高值，为 90.88%；亚纲测试数据集在第 140 次迭代中达到总体准确率最高值，为 93.71%。两个模型的总体准确率均表现良好，意味着基于深度学习的土壤类型识别是可行的。基于相同的原始剖面图像数据集在分类层级深化下训练的模型，其总体准确率也会得到加强，这意味着在层级深化的过程中，不同土壤类型图像之间的差异会减少，从而更容易被模型提取特征并加以识别。

（2）模型针对不同土壤类型的识别能力差异。

本研究认为对模型的识别能力产生较大影响的主要因素有以下三点：1）土壤类型的检索条件在 RGB 图像形成的视觉特征是否显著；2）研究区土壤样本数据在同一类型内的相似特征重叠程度是否显著；3）不同类型间剖面图像的特征差异是否明显；4）样本数量多少。锥形土及其亚纲湿润锥形土正是因为其检索条件难以让网络找到共性特征而误判最多；新成土、人为土及其亚纲则由于在其各自的类型内相似特征多且与其他类型土壤之间差距明显而误判较少；富铁土、淋溶土及其亚纲在鄂、赣两省交界的研究区内存在部分土壤黏化与富铁铝化同时进行的现象，导致其图像特征差异较低，相互之间误判较多。

（3）模型对不同土壤诊断层类型的识别能力差异。

本文建立的诊断层识别模型，基于两个评价指标，选用的是模型训练过程中第 123 次迭代产生的模型，其均交并比与像素精度分别为 71.24%、82.66%，总体精度以及结果图像表现良好。模型识别能力从强至弱依次为水耕氧化还原层>水耕表层>雏形层>暗瘠、暗沃表层 $\approx$ 淡薄表层>黏化层（低活性富铁层） $\approx$ 黏化层>低活性富铁层。总体上，由于表层土壤腐殖化有机物的积累而颜色较深，具有一定的共性特征，诊断表层的精度表现优于诊断表下层。

具体而言，类似于土壤类型识别模型对不同土壤类型的识别能力差异，每种诊断层根据土壤系统分类中的定义以及诊断条件在 RGB 图像上的视觉特征适用范围是否宽泛、样本数量多少存在着识别能力上的差异。同时，研究区内部分的土壤剖面黏化与富铁铝化同时进行的特例情况对识别能力也产生了较大影响。

5.2 不足与展望

本文基于江西、湖北两省主要土壤类型的 RGB 剖面图像，通过深度学习模型训练得到的土纲与亚纲层级的土壤类型识别模型、土壤诊断层识别模型，均表现较好，满足了现实里土壤相关鉴定识别工作中要求的快速、高效、便捷、廉价等的目标，对土壤信息定量化表达和应用推广具有重要的实际意义。但研究过程中仍有不足之处，有待今后研究解决：

（1）本次研究仅选用湖北、江西两省的土壤数据，导致可识别的类别受限较大。其中对于土壤类型识别研究而言，如果将类别继续深化至土类等更深的层级，将导致原始数据较少且难以数据增强，因此期待后续研究运用数量更多、种类更丰富的图像数据库，并训练得到更泛用的模型；对于土壤诊断层识别研究而言，样本的严重失衡虽然通过调整损失函数抑制了部分梯度的消失，但并不能完全地解决这一问题，对数量较少样本仍然产生了影响，如本研究中的低活性富铁层。

（2）本次研究在图像标注处理土壤层次边界时仅依赖人工标注，导致数据预处理的工作量较大。本文多次强调土壤诊断层识别研究中并非所有土壤层次之间的过渡情况都是突变、清晰、平滑的，除此之外还存在有边界渐变、模糊、波状、不规则、间断等情况，这一情况将对模型的训练产生一定的影响。同时图像标注费时费力，期待今后研究能够在图像标注之前通过图像聚类自动形成标注图像，以减少预

处理的工作量。

（3）本次研究仅通过 RGB 图像进行土壤诊断层识别，不足以反映土壤物理和化学性质。在对一些诊断条件中有对元素含量要求的诊断层（如低活性富铁层）进行识别时，层次的描绘识别可能仍然需要便携式 X 射线荧光仪或可见-近红外光谱技术的共同支持，以量化反映剖面中不同土壤化学性质和元素分布的变化。

（4）在本研究中，类型识别与诊断层识别的研究工作联系较少。而在实际的土壤类型识别工作中，在判断得到剖面中诊断层信息后，在土纲、亚纲层面上的土壤类型将很容易判断，因此，期待在未来的研究中，将这两部分研究工作融合在一起，以提高模型识别精度。

参考文献

1. 曹润芝, 韩斌, 刘嘎琼. 基于联邦学习和改进ResNet的肺炎辅助诊断. 计算机系统应用, 2022, 31: 227-233
2. 高未泽, 陈善雄, 莫伯峰, 杨烨, 苏本朋. R-UNet++: 用于甲骨材质分类的局部分割网络. 计算机辅助设计与图形学学报, 2022, 34: 415-424
3. 龚子同, 张甘霖. 中国土壤系统分类: 我国土壤分类从定性向定量的跨越. 中国科学基金, 2006, 293-296
4. 林志洁, 郑秋岚, 梁涌, 邢卫. 基于内卷U-NET模型的医学图像分割方法. 计算机工程, 2021, 1-9
5. 刘兰军, 翟永庆, 郑俊俊, 范萍萍, 邓莉. 基于深度学习的土壤氮含量可见/近红外光谱建模. 光谱学与光谱分析, 2020, 40: 71-72
6. 鲁梦瑶, 杨凯, 宋鹏飞, 束茹欣, 王萝萍, 杨玉清, 刘慧, 李军会, 赵龙莲, 张晔晖. 基于卷积神经网络的烟叶近红外光谱分类建模方法研究. 光谱学与光谱分析, 2018, 38: 3724-3728
7. 孟祥添, 鲍依临, 官海翔, 钱磊. 基于人工神经网络模型的土壤分类方法. 现代农业科技, 2018, 194-195
8. 牟经瑞. 富铁土、淋溶土在鄂赣地区分布与分界的研究. [硕士学位论文]. 武汉: 华中农业大学图书馆, 2016
9. 邱云飞, 张家欣, 兰海, 宗佳旭. 融合张量合成注意力的改进ResNet图像分类模型. 激光与光电子学进展, 2022, 1-16
10. 苏赋, 吕沁, 罗仁泽. 基于深度学习的图像分类研究综述. 电信科学, 2019, 35: 58-74
11. 孙红, 乔金博, 李松, 李民赞, 宋迪, 乔浪. 基于深度学习的玉米拔节期冠层识别. 农业工程学报, 2021, 37: 53-61
12. 汪海洋, 潘德炉, 夏德深. 二维Otsu自适应阈值选取算法的快速实现. 自动化学报, 2007, 968-971
13. 王腊红, 陈家赢, 汪善勤, 王天巍, 谭黄元. 基于本体的土壤系统分类逻辑表达与检索. 土壤学报, 2020, 57: 1378-1386
14. 王天巍. 中国土系志·湖北卷. 北京: 科学出版社, 2017
15. 王天巍, 陈家赢. 中国土系志·江西卷. 北京: 科学出版社, 2021
16. 王鑫, 张昊宇, 凌诚. 基于U-Net优化的SAR遥感图像语义分割. 计算机科学, 2021, 48: 376-381
17. 杨家伟, 王天巍, 包莹莹, 罗梦雨, 李德成. 黏粒阳离子交换量估测模型的优化研究. 土壤学报, 2021, 58: 514-525
18. 杨真真, 匡楠, 范露, 康彬. 基于卷积神经网络的图像分类算法综述. 信号处理, 2018, 34: 1474-1489
19. 张甘霖, 李德成. 野外土壤描述与采样手册. 北京: 科学出版社, 2016
20. 张甘霖, 王秋兵, 张凤荣, 吴克宁, 蔡崇法, 章明奎, 李德成, 赵玉国, 杨金玲. 中国土壤系统分类土族和土系划分标准. 土壤学报, 2013, 50: 826-834
21. 曾莉. 基于ResNet50的紫色土图像分类. 现代计算机, 2019, 28-32
22. 张梦雨. 基于ResNet和注意力机制的花卉识别. 计算机与现代化, 2021, 61-67

23. 张鑫, 姚庆安, 赵健, 金镇君, 冯云丛. 全卷积神经网络图像语义分割方法综述. 计算机工程与应用, 2021, 1-16
24. 赵佳琦, 周勇, 何欣, 卜一凡, 姚睿, 郭睿. 基于深度学习的点云分割研究进展分析. 电子与信息学报, 2021, 1-15
25. 赵鑫龙, 彭彦昆, 李永玉, 王亚丽, 赵苗. 基于深度学习的牛肉大理石花纹等级手机评价系统. 农业工程学报, 2020, 36: 250-256
26. 赵志成, 罗泽, 王鹏彦, 李健. 基于深度残差网络图像分类算法研究综述. 计算机系统应用, 2020, 29: 14-21
27. 中国科学院南京土壤研究所土壤系统分类课题组, 中国土壤系统分类课题研究协作组(2001). 中国土壤系统分类检索. 合肥, 中国科学技术大学出版社.
28. 钟亮, 郭熙, 国佳欣, 徐喆, 朱青, 丁萌. 基于不同卷积神经网络模型的红壤有机质高光谱估算. 农业工程学报, 2021, 37: 203-212
29. 周俊宇, 赵艳明. 卷积神经网络在图像分类和目标检测应用综述. 计算机工程与应用, 2017, 53: 34-41
30. 周泽璠. 基于PXRF数据的土壤层次划分与识别研究. [硕士学位论文]. 武汉: 华中农业大学图书馆, 2021
31. 左仁广, 彭勇, 李童, 熊义辉. 基于深度学习的地质找矿大数据挖掘与集成的挑战. 地球科学, 2021, 46: 350-358
32. Al-Shammary AAG, Kouzani AZ, Kaynak A, Khoo SY, Norton M, Gates W. Soil Bulk Density Estimation Methods: A Review. *Pedosphere*, 2018, 28: 581-596
33. Amato G, Falchi F. Local Feature based Image Similarity Functions for kNN Classification. *ICAART 2011 - Proceedings of the 3rd International Conference on Agents and Artificial Intelligence*, 2011, Rome
34. Badrinarayanan V, Kendall A, Cipolla R. SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017, 39: 2481-2495
35. Barra I, Haefele SM, Sakrabani R, Kebede F. Soil spectroscopy with the use of chemometrics, machine learning and pre-processing techniques in soil diagnosis: Recent advances - A review. *TrAC Trends in Analytical Chemistry*, 2021, 135: 116166
36. Benedet L, Faria WM, Silva SHG, Mancini M, Guilherme LRG, Demattê JAM, Curi N. Soil subgroup prediction via portable X-ray fluorescence and visible near-infrared spectroscopy. *Geoderma*, 2020, 365: 114212
37. Boykov YY, Jolly M. Interactive graph cuts for optimal boundary & region segmentation of objects in N-D images. In: *Proceedings Eighth IEEE International Conference on Computer Vision. ICCV 2001*, 2001.
38. Bridges EM. Soil-horizon designations - past use and future prospects. *CATENA*, 1993, 20: 363-373
39. Chen L, Papandreou G, Kokkinos I, Murphy K, Yuille AL. DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs. *IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE*, 2018, 40: 834-848

40. Chen S, Arrouays D, Leatitia Mulder V, Poggio L, Minasny B, Roudier P, Libohova Z, Lagacherie P, Shi Z, Hannam J, Meersmans J, Richer-de-Forges AC, Walter C. Digital mapping of GlobalSoilMap soil properties at a broad scale: A review. *Geoderma*, 2022, 409: 115567
41. Chen Y, Chou FI, Ho W, Tsai J. Classifying microscopic images as acute lymphoblastic leukemia by Resnet ensemble model and Taguchi method. *BMC BIOINFORMATICS*, 2022, 22: 1-21
42. Coudray N, Ocampo PS, Sakellaropoulos T, Narula N, Snuderl M, Fenyo D, Moreira AL, Razavian N, Tsirigos A. Classification and mutation prediction from non-small cell lung cancer histopathology images using deep learning. *NATURE MEDICINE*, 2018, 24: 1559
43. Déniz O, Bueno G, Salido J, De la Torre F. Face recognition using Histograms of Oriented Gradients. *Pattern Recognition Letters*, 2011, 32: 1598-1603
44. Grabner M, Grabner H, Bischof H. Fast Approximated SIFT. *Asian Conference on Computer Vision*, 2006
45. Han P, Dong D, Zhao X, Jiao L, Lang Y. A smartphone-based soil color sensor: For soil type classification. *Computers and Electronics in Agriculture*, 2016, 123: 232-241
46. Han S, Tao W, Wang D, Tai X, Wu X. Image Segmentation Based on GrabCut Framework Integrating Multiscale Nonlinear Structure Tensor. *IEEE Transactions on Image Processing*, 2009, 18: 2289-2302
47. Hartemink AE, Minasny B. Towards digital soil morphometrics. *Geoderma*, 2014, 230-231: 305-317
48. Hartemink AE, Zhang Y, Bockheim JG, Curi N, Silva SHG, Grauer-Gray J, Lowe DJ, Krasilnikov P. Chapter Three - Soil horizon variation: A review. In: Sparks DL eds., *Advances in Agronomy*. Academic Press, 2020. 125-185
49. He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. In: 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016
50. He K, Zhang X, Ren S, Sun J. Identity Mappings in Deep Residual Networks. In: Leibe B, Matas J, Sebe N, Welling M, *Computer Vision - ECCV 2016*, Cham, 2016, Springer International Publishing
51. He L, Zou C, Zhao L, Hu D. An Enhanced LBP Feature Based on Facial Expression Recognition. In: 2005 IEEE Engineering in Medicine and Biology 27th Annual Conference, 2005
52. Hossain MS, Betts JM, Paplinski AP. Dual Focal Loss to address class imbalance in semantic segmentation. *NEUROCOMPUTING*, 2021, 462: 69-87
53. Hughes P, McBratney AB, Minasny B, Huang J, Micheli E, Hempel J, Jones E. Comparisons between USDA soil taxonomy and the Australian Soil Classification system II: Comparison of order, suborder and great group taxa. *Geoderma*, 2018, 322: 48-55
54. Jiang Z, Owens PR, Zhang C, Brye KR, Weindorf DC, Adhikari K, Sun Z, Sun F, Wang Q. Towards a dynamic soil survey: Identifying and delineating soil horizons in-situ using deep learning. *Geoderma*, 2021, 401: 115341

55. Jiang Z, Wang Q, Brye KR, Adhikari K, Sun F, Sun Z, Chen S, Owens PR. Quantifying organic carbon stocks using a stereological profile imaging method to account for rock fragments in stony soils. *Geoderma*, 2021, 385: 114837
56. Jiang Z, Wang Q, Libohova Z, Adhikari K, Brye KR, Sun Z, Sun F, Jiang Y, Owens PR. Fe-Mn concentrations in upland loess soils in mid-continental north America: A step towards dynamic soil survey. *CATENA*, 2021, 202: 105273
57. Joachims T. Making Large-scale SVM Learning Practical. *Advances in Kernel Methods Support Vector Learning*, 2006, 3: 499-526
58. Krizhevsky A, Sutskever I, Hinton GE. ImageNet Classification with Deep Convolutional Neural Networks. *Advances in neural information processing systems*, 2012, 2: 1097-1105
59. Liu P, Song Y, Chai M, Han Z, Zhang Y. Swin - UNet++: A Nested Swin Transformer Architecture for Location Identification and Morphology Segmentation of Dimples on 2.25Cr1Mo0.25V Fractured Surface. *Materials*, 2021, 14
60. Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation. In: 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015
61. Ma L, Li M, Ma X, Cheng L, Du P, Liu Y. A review of supervised object-based land-cover image classification. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2017, 130: 277-293
62. Micallef N, Seychell D, Claude JB. A Nested U-Net Approach for Brain Tumour Segmentation. 2020 IEEE 20th Mediterranean Electrotechnical Conference (MELECON), 2020
63. Mohamed AA, Berg WA, Peng H, Luo Y, Jankowitz RC, Wu S. A deep learning method for classifying mammographic breast density categories. *MEDICAL PHYSICS*, 2018, 45: 314-321
64. Otsuka H, Takemoto K. Deep learning and k-means clustering in heterotic string vacua with line bundles. *Journal of High Energy Physics*, 2020, 2020: 47
65. Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation. *Proceedings of the International Conference on Medical Image Computing and Computer-Assisted Intervention*, 2015
66. Russell BC, Torralba A, Murphy KP, Freeman WT. LabelMe: A database and web-based tool for image annotation. *INTERNATIONAL JOURNAL OF COMPUTER VISION*, 2008, 77: 157-173
67. Searle R, McBratney A, Grundy M, Kidd D, Malone B, Arrouays D, Stockman U, Zund P, Wilson P, Wilford J, Van Gool D, Triantafilis J, Thomas M, Stower L, Slater B, Robinson N, Ringrose-Voase A, Padarian J, Payne J, Orton T, Odgers N, O'Brien L, Minasny B, Bennett JM, Liddicoat C, Jones E, Holmes K, Harms B, Gray J, Bui E, Andrews K. Digital soil mapping and assessment for Australia and beyond: A propitious future. *Geoderma Regional*, 2021, 24: 359
68. Szegedy C, Liu W, Jia Y, Sermanet P, Reed S, Anguelov D, Erhan D, Vanhoucke V, Rabinovich A. Going deeper with convolutions. In: 2015 IEEE Conference on

- Computer Vision and Pattern Recognition (CVPR), 2015
69. Weindorf DC, Zhu Y, Haggard B, Lofton J, Chakraborty S, Bakr N, Zhang W, Weindorf WC, Legoria M. Enhanced Pedon Horizonation Using Portable X-ray Fluorescence Spectrometry. SOIL SCIENCE SOCIETY OF AMERICA JOURNAL, 2012, 76: 522-531
70. Wu Z, Shen C, van den Hengel A. Wider or Deeper: Revisiting the ResNet Model for Visual Recognition. Pattern Recognition, 2019, 90: 119-133
71. Xie X, Li A. Identification of soil profile classes using depth-weighted visible - near-infrared spectral reflectance. Geoderma, 2018, 325: 90-101
72. Yang L, Wu X, Zhao D, Li H, Zhai J. An improved Prewitt algorithm for edge detection based on noised image. In:2011 4th International Congress on Image and Signal Processing, 2011
73. Yeung M, Sala E, Schonlieb C, Rundo L. Unified Focal loss: Generalising Dice and cross entropy-based losses to handle class imbalanced medical image segmentation. Computerized medical imaging and graphics : the official journal of the Computerized Medical Imaging Society, 2022, 95: 102026
74. Zhang J, Lin H, Doolittle J. Soil layering and preferential flow impacts on seasonal changes of GPR signals in two contrasting soils. Geoderma, 2014, 213: 560-569
75. Zhang Y, Hartemink AE. Sampling designs for soil organic carbon stock assessment of soil profiles. Geoderma, 2017, 307: 220-230
76. Zhang Y, Hartemink AE. A method for automated soil horizon delineation using digital images. Geoderma, 2019, 343: 97-115
77. Zhao W, Zhao Y, Feng L, Tang J. Attention Enhanced Serial Unet++ Network for Removing Unevenly Distributed Haze. Electronics, 2021
78. Zhou Z, Rahman Siddiquee MM, Tajbakhsh N, Liang J. UNet++: A Nested U-Net Architecture for Medical Image Segmentation. Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support, 2018